Revisión de la elaboración de índices pronóstico en regresión logística

Antonio Luque Ruiz
Tutor: Prof. Francisco Javier Martín Vallejo
Trabajo de Fin de Máster

Universidad de Salamanca
Máster Universitario en Análisis Avanzado de Datos Multivariante y Big Data

16 de julio de 2025

Introducción: El Problema Clínico

El Contexto

- En la práctica clínica se necesita estratificar el riesgo de los pacientes de forma rápida y fiable.
- La Regresión Logística es el método estadístico de referencia para este propósito.

Los Retos

Sin embargo, existen dos grandes desafíos:

- La **selección de variables** con información clínicamente relevante es un proceso complejo y crítico.
- La **interpretación del modelo** es difícil, ya que sus resultados directos (coeficientes β) son poco intuitivos para un médico.

VNiVERSiDAD DE SALAMANCA

Objetivos del Trabajo

Objetivo General

Revisar y aplicar el proceso completo para transformar un modelo logístico en un **índice pronóstico (score) robusto y clínicamente útil**.

Objetivo Específico

Desarrollar y validar un score para predecir la **mortalidad a 6 meses** en pacientes con insuficiencia cardíaca, a partir de un conjunto de datos real.

VNiVERSiDAD DE SALAMANCA

Esquema del Proceso: De los Datos al Score Clínico

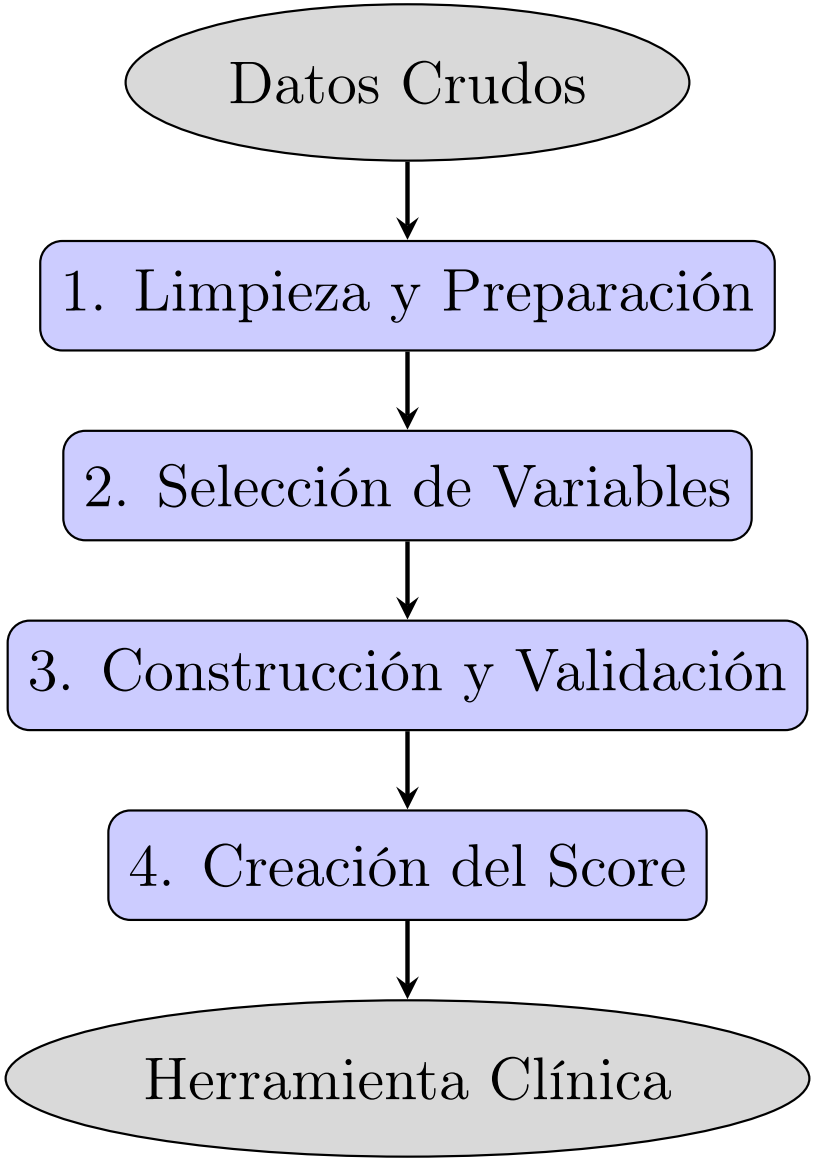

VNiVERSiDAD D SALAMANCA

Los Datos: Fuente y Objetivo del Estudio

Fuente de los Datos

- **Origen:** Dataset público de **Physionet** (Gu et al., 2022).
- **Población:** Cohorte retrospectiva de **2,008 pacientes** ingresados por insuficiencia cardíaca.
- **Datos Iniciales: 168 variables** que abarcan un amplio espectro de información:
  - Características demográficas.
  - Datos clínicos basales al ingreso.
  - Hallazgos de laboratorio.
  - Comorbilidades y hallazgos ecocardiográficos.

Objetivo del Estudio

Predecir la **mortalidad por insuficiencia cardíaca a los 6 meses**.

VNiVERSiDAD DE SALAMANCA

Etapa 1: Limpieza y Preparación

Pasos para asegurar la calidad del dato

Se siguió un proceso riguroso para preparar el dataset final para el análisis:

1. **Prevención de Fuga de Datos:** Se eliminaron todas las variables no disponibles en el momento del diagnóstico.
2. **Eliminación de Variables No Útiles:** Se descartaron IDs, datos redundantes y variables administrativas no generalizables.
3. **Gestión de Datos Faltantes:**
   - Exclusión de variables con >50% de datos ausentes.
   - Imputación simple para el resto: **mediana** (numéricas) y **moda** (categóricas).

Resultado del Proceso

Dataset final limpio con **116 variables candidatas** para la selección.

Etapa 2: Opciones para la Selección de Variables

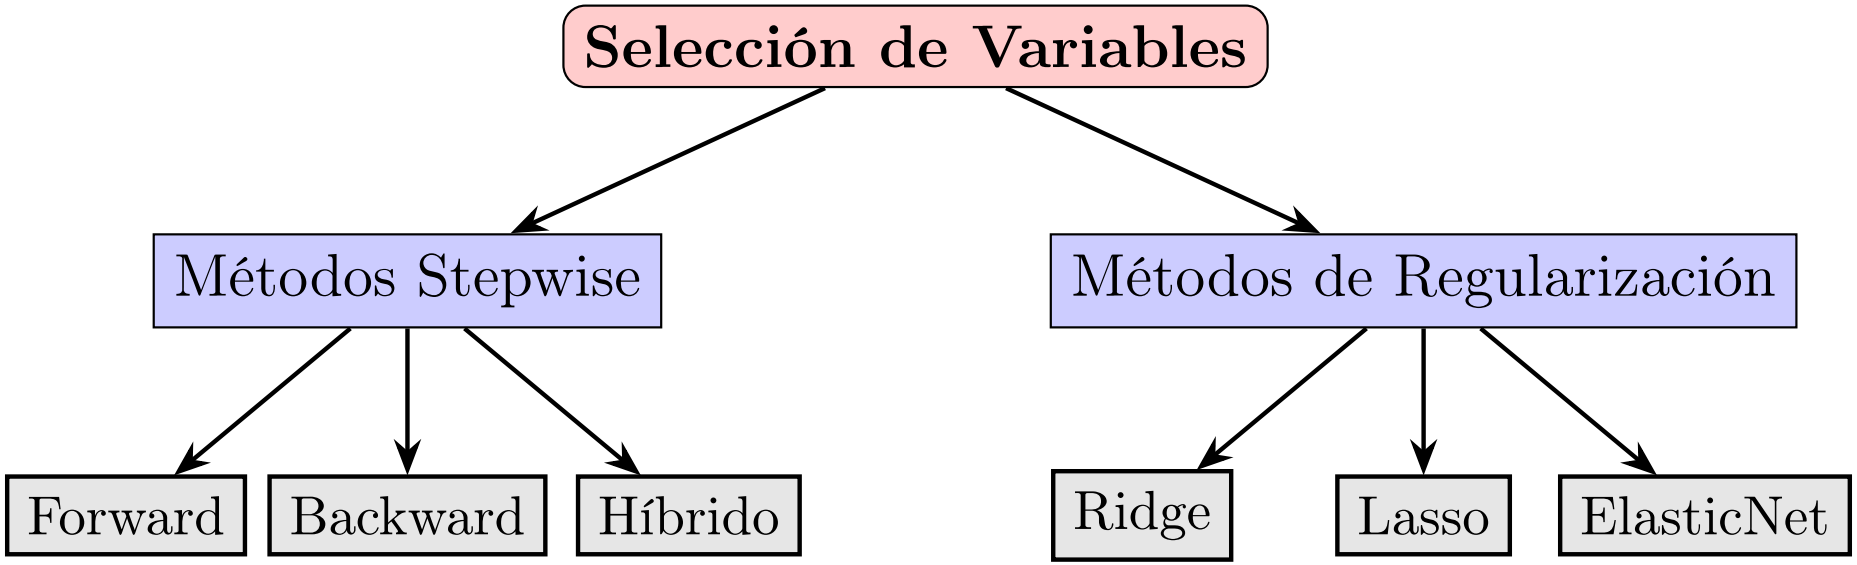

Etapa 2: Selección de Variables

Nuestra Elección: Regularización LASSO

- **¿Por qué LASSO?**
  - Ideal para **alta dimensionalidad** (muchos predictores).
  - Realiza una **selección automática** de variables al forzar a cero los coeficientes de las menos importantes.
  - Es una técnica poderosa para prevenir el **sobreajuste**.
- **Resultado:** De 116 variables, LASSO seleccionó un subconjunto final y manejable de **20 predictores** para la construcción del modelo.

VNiVERSiDAD D SALAMANCA

Etapa 3: Validación (Parte I - Discriminación)

Pregunta Clave: ¿El modelo distingue bien a los pacientes?

- Se evaluó la capacidad del modelo para diferenciar entre pacientes de alto y bajo riesgo de mortalidad (Harrell, 2015).
- **Métrica utilizada:** Área Bajo la Curva ROC (AUC).

Resultado

$$\text{AUC} = 0.910$$

(Discriminación Excelente)

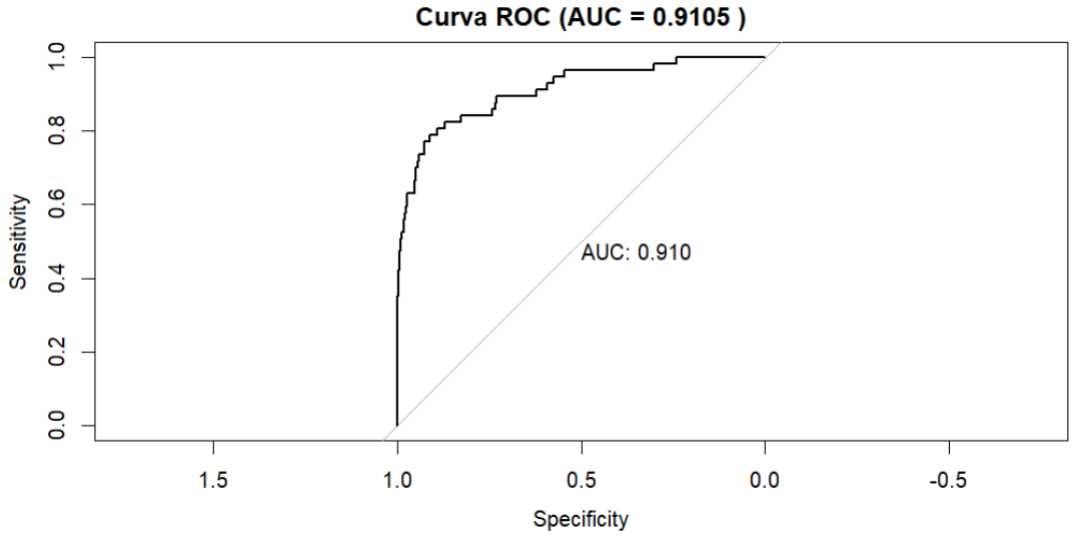

Figura 1: Curva ROC del modelo final.

Etapa 3: Validación (Parte II - Calibración)

Pregunta Clave: ¿Son acertadas las predicciones del modelo?

- Se evaluó si las probabilidades de riesgo predichas por el modelo se ajustan a las frecuencias de riesgo observadas en la realidad (Hosmer and Lemeshow, 1980).
- **Métrica utilizada:** Gráfico de Calibración.

Resultado

Calibración Visual Excelente

(La línea del modelo sigue casi perfectamente la línea ideal)

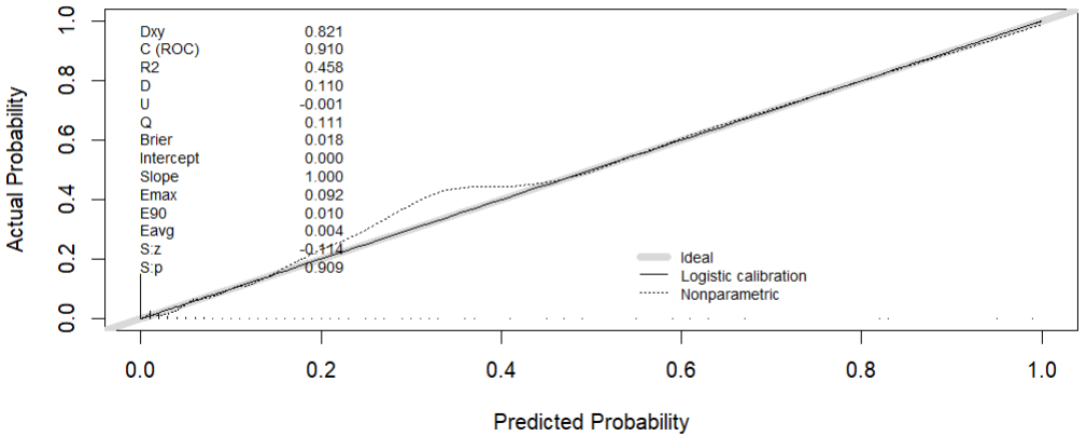

Figura 2: Gráfico de Calibración del modelo.

Etapa 4: De los Coeficientes al Score Clínico (I)

El Método: Transformación a Puntos Nguyen and Graviss (2018)

Para convertir el modelo en un score simple, se siguió un método clásico (Steyerberg, 2019):

1. Se ajustó el modelo final con las variables ya categorizadas.
2. Se identificó el coeficiente (β) con el valor absoluto más pequeño como unidad de referencia (β_{ref}).
3. Se calcularon los puntos para cada predictor y se redondearon al entero:

$$Puntos = redondeo\left(\frac{\beta}{\beta_{ref}}\right)$$

VNiVERSiDAD D SALAMANCA

Etapa 4: De los Coeficientes al Score Clínico (II)

La Herramienta Final: Estratificación del Riesgo

Grupo de Riesgo	Puntuación Requerida
Bajo ($<$ 20% Mort.)	$<$ -116
Medio (20-70% Mort.)	-116 a 71
Alto ($>$ 70% Mort.)	$>$ 71

Aplicación: El clínico suma los puntos de su paciente y usa esta tabla para estratificar su riesgo de forma inmediata.

VNiVERSiDAD D SALAMANCA

Conclusiones y Líneas Futuras

- La regularización **LASSO** es una herramienta metodológica superior a los enfoques clásicos para la selección de variables en contextos de alta dimensionalidad.
- El score desarrollado demuestra una **excelente capacidad de discriminación (AUC = 0.910)**, siendo una herramienta muy eficaz para diferenciar entre pacientes de alto y bajo riesgo de mortalidad.
- Se confirma que los scores pronóstico son un **puente esencial** entre la modelización estadística compleja y la toma de decisiones en la práctica clínica diaria.
- **Línea Futura Prioritaria:** Es fundamental realizar la **validación externa** del score para confirmar su generalizabilidad antes de una posible implementación clínica.

VNiVERSiDAD D SALAMANCA

Bibliografía I

Gu, W., Wang, F., Liu, T., and Qin, Y. (2022). *A new predictor of all-cause mortality in patients with heart failure: The waist-to-height ratio.* BMC Medical Informatics and Decision Making,.

Harrell, F. E. (2015). *Regression modeling strategies: with applications to linear models, logistic regression, and survival analysis (2nd ed.).* Springer.

Hosmer, D. W. and Lemeshow, S. (1980). *A goodness-of-fit test for the multiple logistic regression model.* Communications in Statistics-Theory and Methods,.

Nguyen, L. and Graviss, E. A. (2018). A simple prognostic score for tuberculosis mortality in texas. *Journal of Clinical Epidemiology*, 95:56–65.

Steyerberg, E. W. (2019). *Clinical Prediction Models: A Practical Approach to Development.* Springer Nature.

VNiVERSiDAD DE SALAMANCA

¡Muchas gracias por su atención!

VNiVERSiDAD
D SALAMANCA