Universidad de Salamanca
Facultad de Medicina

Revisión de la elaboración de índices pronóstico en regresión logística

A Review of the Development of Prognostic Scores in Logistic Regression

Trabajo Fin de Máster en Análisis Avanzado de Datos Multivariante y Big Data

---

Autor: Antonio Luque Ruiz

Área de conocimiento y/o departamento: Estadística

Fecha de presentación: Julio de 2025

Departamento de Estadística
UNIVERSIDAD DE SALAMANCA

Francisco Javier MARTÍN VALLEJO

Profesor Titular del Departamento de Estadística de la Universidad de Salamanca

HACE CONSTAR que el trabajo titulado *Revisión de la elaboración de índices pronóstico en regresión logística*, que se presenta, ha sido realizado por **Antonio Luque Ruiz** y constituye la memoria del trabajo realizado para la superación de la asignatura Trabajo de Fin de Máster en esta Universidad.

Salamanca, 8 de julio de 2025.

MARTIN VALLEJO FRANCISCO JAVIER - 16797670B

MARTIN VALLEJO FRANCISCO JAVIER - 16797670B

Francisco Javier MARTÍN VALLEJO

Fdo:.....

Índice general

Resumen iv

Introducción iv

1. Revisión metodológica 1
1. Modelo logístico . . . 1
2. Interpretación de los coeficientes β en el contexto pronostico . . . 2
3. Interpretación de los Odds Ratios (OR) en el contexto pronóstico . . . 3
4. Selección de variables . . . 4
   4.1. Búsqueda Stepwise . . . 4
   4.2. Regularización (Shrinkage) . . . 9
5. Categorización de variables cuantitativas . . . 12
   5.1. Métodos de Binning No Supervisados . . . 12
   5.2. Métodos de Binning Supervisados . . . 14

2. Validación del Modelo Pronóstico 17
1. Evaluación del Rendimiento . . . 17
   1.1. Discriminación . . . 17
   1.2. Calibración . . . 19
   1.3. Otras métricas relevantes . . . 22
2. Estrategias de validación . . . 23
   2.1. Validación Interna . . . 23
   2.2. Validación Externa . . . 26
   2.3. Transparencia en la publicación de resultados: Adhesión a Directrices como TRIPOD . . . 29

3. Scores pronóstico 31
1. Elaboración de Índices Pronóstico (Scores) a partir de Coeficientes Logísticos 31
   1.1. Principios Metodológicos . . . 31
   1.2. Descripción del Método Clásico de Asignación de Puntos . . . 32
   1.3. Ejemplo Práctico . . . 35
2. Herramientas de Software (R) Recomendadas . . . 36

4. Aplicación Práctica 39
1. Descripción de los datos . . . 39
2. Metodología . . . 39
   2.1. Limpieza de Datos . . . 39
   2.2. Selección de variables predictoras . . . 41
   2.3. Construcción del Modelo Logístico . . . 42

2.4. Construcción del Modelo pronóstico 43
3. Resultados 43
3.1. Análisis univariado 43
3.2. Modelo Logístico 44
3.3. Validación 45
3.4. Modelo Pronóstico 46

5. Conclusiones **51**

Bibliografía **52**

Resumen

En la práctica clínica es fundamental disponer de herramientas que permitan la estratificación del riesgo de los pacientes de forma rápida y fiable. El método estadístico de referencia para este fin, cuando el resultado es binario, es la Regresión Logística, que se considera un caso particular del modelo lineal generalizado. El problema principal de la regresión logística es que sus resultados directos (coeficientes en la escala log-odds) son poco intuitivos para su uso inmediato en la toma de decisiones. Además, su construcción es un proceso complejo que requiere una selección de variables rigurosa para controlar el riesgo de sobreajuste y una validación exhaustiva para garantizar su fiabilidad. En este trabajo se revisa y aplica el proceso completo para transformar un modelo logístico en un índice pronóstico (score) robusto y clínicamente útil. En el primer capítulo se describe el fundamento del modelo logístico, las estrategias para la selección de variables, desde los métodos clásicos stepwise hasta la regularización LASSO, y las técnicas de categorización. El segundo capítulo se centra en la validación del modelo, detallando las métricas de rendimiento como la discriminación (AUC) y la calibración. En el tercer capítulo se explica el método clásico para convertir los coeficientes del modelo en un sistema de puntos simple y aditivo. Finalmente, en el cuarto capítulo, se aplica toda la metodología descrita para desarrollar y validar un score pronóstico de mortalidad a 6 meses a partir de un conjunto de datos real de pacientes con insuficiencia cardíaca, ilustrando el proceso desde la limpieza de los datos hasta la obtención de la herramienta final.

Palabras clave:

Regresión Logística, Índice Pronóstico, Score Clínico, Selección y categorización de Variables, LASSO, Validación de Modelos, Insuficiencia Cardíaca.

Introducción

En las últimas décadas, el avance de las técnicas estadísticas aplicadas a la medicina ha permitido la construcción de modelos predictivos cada vez más precisos, cuyo objetivo principal es apoyar la toma de decisiones clínicas (Steyerberg et al., 2013). En este contexto, la regresión logística se ha consolidado como una de las herramientas más ampliamente utilizadas cuando el desenlace clínico es de tipo binario, como por ejemplo la presencia o ausencia de una enfermedad, el éxito o fracaso terapéutico, o la supervivencia frente a la muerte (Hosmer and Lemeshow, 1980).

Particularmente en el ámbito clínico, el interés no se limita únicamente a estimar la probabilidad de ocurrencia de un evento, sino a traducir estas probabilidades en índices pronóstico o scores clínicos. Esta transformación es crucial, ya que los resultados directos de un modelo de regresión, como los coeficientes expresados en la escala de log-odds, son poco intuitivos para su aplicación en el dinámico entorno de una consulta. Estas herramientas de puntuación permiten, de forma rápida y comprensible, clasificar a los pacientes en diferentes categorías de riesgo, lo que tiene un valor incalculable en la práctica médica. Herramientas ampliamente adoptadas, como el Framingham Risk Score para enfermedad cardiovascular o la variedad de calculadoras disponibles en plataformas como MDCalc, demuestran que su uso permite optimizar la asignación de recursos, personalizar tratamientos, anticipar intervenciones en pacientes de alto riesgo y mejorar la comunicación con el paciente, involucrándolo en las decisiones sobre su salud (Hemingway et al., 2013; Visseren et al., 2021).

Un modelo pronóstico robusto y fiable no se construye únicamente a partir de una regresión logística ajustada, sino que requiere una serie de decisiones metodológicas fundamentales: la selección adecuada de variables predictoras, el tratamiento correcto de variables cuantitativas, la transformación de coeficientes en puntuaciones comprensibles y, por último pero no menos importante, la validación del modelo (Steyerberg, 2019). Esta simplificación de un modelo complejo a un score numérico no es una mera conveniencia, sino una condición indispensable para la adopción generalizada y el impacto real de los modelos predictivos en la mejora de la atención al paciente.

La literatura médica muestra múltiples ejemplos exitosos de modelos pronósticos basados en regresión logística. Por ejemplo, el estudio de Nguyen and Graviss (2018) desarrolló un índice pronóstico para predecir la mortalidad en pacientes con tuberculosis en el estado de Texas, usando variables demográficas y clínicas fácilmente disponibles en la visita inicial. A través de una cuidadosa selección de variables, la categorización por puntuaciones y una validación interna sólida, consiguieron una herramienta de uso práctico con alto valor predictivo. Este tipo de modelos pone de manifiesto cómo los métodos estadísticos, cuando se aplican rigurosamente, pueden tener un impacto directo y positivo en la atención médica.

El presente trabajo de fin de máster tiene como finalidad revisar de forma crítica y práctica las distintas etapas implicadas en la construcción de índices pronóstico median-

te modelos de regresión logística. Para ello, se abordarán los distintos métodos para la selección de variables, la categorización de predictores cuantitativos, la elaboración del índice propiamente dicho y los procedimientos de validación interna y externa. Además, se explorarán las herramientas disponibles en el software estadístico R para implementar dichos métodos. Finalmente, se aplicará toda la metodología revisada a un conjunto de datos reales, con el fin de ilustrar de forma aplicada todo el proceso.

La elaboración de índices pronóstico no solo representa un ejercicio técnico, sino que constituye el fundamento estadístico para el desarrollo de modelos de inteligencia artificial capaces de guiar las decisiones médicas (Benavent et al., 2020). Estos modelos, al ser interpretables y estar debidamente validados, representan una oportunidad para acercar la estadística a la práctica clínica y mejorar la calidad del cuidado a los pacientes. Este trabajo pretende contribuir a ese puente entre la estadística fundamental y sus aplicaciones modernas, mediante una revisión estructurada, crítica y aplicada de los métodos más relevantes en regresión logística con fines pronósticos.

Capítulo 1

Revisión metodológica

La construcción de un modelo pronóstico mediante regresión logística implica una serie de decisiones metodológicas clave que afectan directamente a su validez, utilidad clínica e interpretabilidad. Más allá del ajuste de un modelo estadístico, es fundamental revisar y comprender los pasos previos y posteriores al modelado, que abarcan desde la selección adecuada de variables predictoras hasta la validación y evaluación del desempeño del modelo.

En este apartado se presentan los principales aspectos metodológicos implicados en la elaboración de índices pronóstico basados en regresión logística. Para ello, se abordarán distintas estrategias para la selección de variables, la categorización de predictores cuantitativos, la transformación del modelo en una herramienta aplicable (score pronóstico), los criterios de validación estadística, y el uso de software especializado, principalmente en el entorno R. Esta revisión se orienta a ofrecer una perspectiva crítica, práctica y actualizada sobre las herramientas más utilizadas en la literatura científica para el desarrollo de modelos pronósticos clínicos.

1 Modelo logístico

El modelo de regresión logística múltiple es la base matemática para la estimación de probabilidades en escenarios con resultados binarios. La ecuación fundamental que describe esta relación es:

$$P(\mathbf{X}) = \frac{\exp(\beta_0 + \beta_1 X_1 + \ldots + \beta_k X_k)}{1 + \exp(\beta_0 + \beta_1 X_1 + \ldots + \beta_k X_k)}$$

o, equivalentemente:

$$P(\mathbf{X}) = \frac{1}{1 + \exp(-(\beta_0 + \beta_1 X_1 + \ldots + \beta_k X_k))},$$

donde $P(\mathbf{X})$ representa la probabilidad de que ocurra el evento de interés (comúnmente denominado ”éxito”, por ejemplo, desarrollar una enfermedad) dado un conjunto de variables predictoras X_1,X_2 , ..., X_k. Los términos β_0,β_1,β_2, ..., β_k son los coeficientes del modelo: β_0 es el intercepto (el log-odds del evento cuando todos los predictores son cero o están en su categoría de referencia), y los demás son los coeficientes asociados a cada variable predictora. Una propiedad esencial de esta función logística (también conocida como función sigmoidea) es que transforma una combinación lineal de los predictores (el

término $\beta_0 + \beta_1 X_1 + \ldots + \beta_k X_k$, que puede tomar cualquier valor real) en una probabilidad que siempre se encuentra entre 0 y 1, lo cual es indispensable para la interpretación probabilística.
Para facilitar la estimación e interpretación de los coeficientes, la ecuación logística se expresa frecuentemente en términos del logaritmo de las odds (log-odds), también conocido como la transformación logit:

$$\text{logit}(P) = \log\left(\frac{P}{1-P}\right) = \beta_0 + \beta_1 X_1 + \ldots + \beta_k X_k.$$

Aquí, $\frac{P}{1-P}$ epresenta las "odds" o la razón de probabilidades del evento. Esta transformación es crucial porque linealiza la relación entre los predictores y la función de probabilidad transformada. Es en esta escala logit donde los efectos de los predictores son aditivos, y es a partir de esta linealidad que se estiman los coeficientes β mediante métodos como la estimación por máxima verosimilitud.

2 Interpretación de los coeficientes β en el contexto pronostico

Los coeficientes de regresión logística, denotados como β_j para la j-ésima variable predictora, son elementos centrales en la interpretación de un modelo pronóstico. Cada coeficiente β_j cuantifica el cambio en el logaritmo de las odds (log-odds) del resultado de interés por cada incremento de una unidad en la variable predictora X_j, asumiendo que todas las demás variables predictoras en el modelo se mantienen constantes.

El signo del coeficiente β_j indica la dirección de la asociación:

- Un β_j positivo implica que un aumento en el valor de X_j(o la presencia del factor si X_j es binaria) se asocia con un aumento en las log-odds del evento, y por lo tanto, con una mayor probabilidad del evento.
- Un β_j negativo sugiere que un aumento en X_j se asocia con una disminución en las log-odds del evento, indicando un factor protector o una menor probabilidad del evento.
- Un β_j cercano a cero indica una asociación débil o nula entre X_j y el log-odds del evento, después de ajustar por los otros predictores.

La significancia estadística de cada coeficiente individual se evalúa comúnmente mediante la prueba de Wald. Esta prueba contrasta la hipótesis nula de que el coeficiente es cero en la población ($H_0 : \beta_j = 0$), lo que implicaría que la variable predictora no tiene un efecto significativo sobre el resultado después de considerar las otras variables. El estadístico de Wald, $W = \left(\frac{\hat{\beta}_j}{EE(\hat{\beta}_j)}\right)^2$ sigue aproximadamente una distribución normal estándar bajo la hipótesis nula. Un valor p pequeño asociado a esta prueba sugiere que se rechaza la hipótesis nula y que el predictor tiene una influencia estadísticamente significativa en el pronóstico.

La magnitud y la significancia estadística de un coeficiente β son determinantes directos de la ponderación o importancia que una variable predictora recibirá al construir un índice pronóstico sumativo. Las variables con coeficientes β de mayor valor absoluto (es

decir, más alejados de cero) y que son estadísticamente significativos tendrán un impacto considerablemente mayor en la puntuación final del score y, por ende, en la estimación del riesgo. Esto se debe a que el propósito de un score pronóstico es reflejar fielmente el riesgo predicho por el modelo de regresión logística subyacente. Dado que los coeficientes β cuantifican la fuerza de la asociación entre cada predictor y el log-odds del resultado , es lógico que los puntos asignados en un score sean proporcionales a estos coeficientes.
Si un coeficiente β es grande, indica una fuerte asociación (ya sea de riesgo o protección), y por lo tanto, esa variable debe contribuir con una mayor cantidad de puntos (positivos o negativos, o modular la puntuación de forma más sustancial) al score global.

3 Interpretación de los Odds Ratios (OR) en el contexto pronóstico

El Odds Ratio (OR) es una medida de asociación derivada directamente de los coeficientes de la regresión logística y se calcula como la exponencial del coeficiente β_j: $OR_j = \exp(\beta_j)$. El OR representa el factor por el cual cambian las odds del evento de interés por cada incremento de una unidad en la variable predictora X_j, manteniendo constantes las demás variables.
La interpretación del OR es la siguiente :

- Si $OR_j = 1$ (lo que ocurre si $\beta_j = 0$), no hay asociación entre el predictor X_j y las odds del evento.
- Si $OR_j > 1$ (cuando $\beta_j > 0$), un incremento unitario en X_j(o la presencia del factor si X_j es binaria) se asocia con un aumento en las odds del evento. Por ejemplo, un OR de 2.0 significa que las odds del evento se duplican por cada unidad de aumento en X_j.
- Si $OR_j < 1$ (cuando $\beta_j < 0$), un incremento unitario en X_j se asocia con una disminución en las odds del evento, indicando un factor protector. Por ejemplo, un OR de 0.5 significa que las odds del evento se reducen a la mitad por cada unidad de aumento en X_j.

Es fundamental considerar el intervalo de confianza (IC) del 95 % para el OR. Este intervalo proporciona un rango de valores plausibles para el OR poblacional y refleja la precisión de la estimación del OR. Si el IC del 95 % para un OR no incluye el valor 1.0, se considera que la asociación es estadísticamente significativa al nivel del 5 %. Un IC amplio sugiere una estimación imprecisa, a menudo debido a un tamaño muestral pequeño o a una alta variabilidad.

Tomemos un ejemplo conceptual en un contexto pronóstico: si en un modelo para predecir la mortalidad a 30 días, la variable "edad avanzada ($\geq$ 75 años vs <75 años)" tiene un $\beta = 0.693$, el OR sería $\exp(0.693) \approx 2.0$. Esto se interpretaría como que los pacientes de edad avanzada tienen el doble de odds de mortalidad a 30 días en comparación con los pacientes más jóvenes, ajustando por otros factores incluidos en el modelo.

Aunque los coeficientes β constituyen la base matemática para la construcción de los scores, los ORs son frecuentemente más intuitivos para los clínicos al comunicar la magnitud del riesgo relativo asociado a un factor. No obstante, para la creación de scores sumativos simples, que es el objetivo de muchos índices pronósticos, los coeficientes β (o una transformación lineal directa de ellos) son más directamente utilizables que los

ORs. Esto se debe a que los β son aditivos en la escala logit, que es la escala en la que el modelo logístico es lineal: $logit(P) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots$. Los scores buscan replicar esta aditividad sumando puntos. Por el contrario, los ORs, al ser $\exp(\beta_j)$, actúan de forma multiplicativa sobre las odds. Convertir directamente ORs en puntos que se puedan sumar de manera lineal es menos directo y matemáticamente menos elegante que utilizar los propios coeficientes β o una escala derivada de ellos. Por esta razón, la mayoría de los métodos para la creación de scores clínicos parten de los coeficientes β del modelo logístico.

4 Selección de variables

La construcción de un modelo pronóstico robusto y clínicamente útil es un procedimiento en el que intervienen diferentes procesos y requiere tomar decisiones en cada uno de ellos. Una de las fases más críticas y determinantes es la selección de variables predictoras. La inclusión de variables irrelevantes o el descarte de aquellas con un verdadero poder predictivo puede comprometer gravemente la validez, la capacidad de generalización y la interpretabilidad del modelo resultante, como vemos en Harrell (2015)

En el contexto de la regresión logística, donde el objetivo es predecir la probabilidad de un evento binario (como la presencia/ausencia de una enfermedad o la muerte), la selección de variables busca identificar el subconjunto óptimo de predictores que maximice el rendimiento del modelo, minimice el riesgo de sobreajuste (overfitting) y, a la vez, garantice la parsimonia y la relevancia clínica. Un modelo con demasiadas variables puede ser inestable y difícil de interpretar, mientras que uno con muy pocas podría carecer de capacidad predictiva.

A lo largo de los años, se han desarrollado diversas estrategias y métodos estadísticos para abordar este desafío. Estos enfoques varían en su complejidad computacional, en los criterios que utilizan para evaluar la ”importancia” de una variable y en cómo manejan aspectos como la multicolinealidad o la interacción entre predictores. Desde los métodos tradicionales de búsqueda paso a paso, basados en la significación estadística, hasta las técnicas de regularización más modernas que incorporan penalizaciones para la complejidad del modelo, cada aproximación ofrece ventajas y desventajas que deben ser cuidadosamente consideradas en función de las características de los datos y los objetivos del estudio.

En esta sección, se revisarán los principales métodos para la selección de variables en modelos de regresión logística, analizando su fundamento teórico, su procedimiento de aplicación y sus implicaciones prácticas en la construcción de índices pronósticos. Se abordarán tanto los algoritmos de selección clásicos como las técnicas más avanzadas que permiten una gestión más eficiente de la dimensionalidad de los datos y una mayor robustez del modelo. Este análisis es fundamental para comprender cómo se construye un modelo predictivo que sea tanto estadísticamente sólido como clínicamente relevante.

Para una comprensión exhaustiva de las estrategias de selección de variables, los siguientes apartados explorarán las diferentes aproximaciones metodológicas, desde las técnicas clásicas hasta las más avanzadas, así como la importancia del juicio clínico.

4.1. Búsqueda Stepwise

Los métodos de búsqueda paso a paso, conocidos comúnmente como ”stepwise”, representan una clase de algoritmos de selección de variables que construyen o refinan un

modelo predictivo de manera iterativa. Su atractivo radica en su simplicidad conceptual y en la automatización del proceso de identificación de un subconjunto ”óptimo” de predictores a partir de un conjunto más amplio de variables candidatas. Aunque han sido ampliamente utilizados, es fundamental comprender su funcionamiento detallado, así como sus inherentes ventajas y limitaciones. Se pueden consultar los aspectos técnicos en Hosmer et al. (2013),

El principio fundamental detrás de los métodos stepwise es la adición o eliminación secuencial de variables al modelo, basándose en la mejora que estas aportan a un criterio estadístico predefinido. Este proceso iterativo continúa hasta que ningún cambio adicional mejora el criterio de manera significativa.

La decisión de añadir o eliminar una variable en cada paso se basa en la evaluación de cómo esa variable afecta la bondad de ajuste del modelo. Los criterios más comunes utilizados en la regresión logística son:

- **Test de la Razón de Verosimilitud (LRT):** Este criterio es uno de los más utilizados para la selección de variables, ya que compara directamente la bondad de ajuste entre dos modelos jerárquicos. Un modelo se considera jerárquico dentro de otro si sus variables son un subconjunto de las variables del modelo más complejo. Esta es precisamente la situación en cada iteración de un procedimiento stepwise. El test se basa en la diferencia de las log-verosimilitudes de los dos modelos. El estadístico de prueba, conocido como G^2, se calcula de la siguiente manera:

  $$G^2 = 2(\textit{log-verosimilitud}_{\textit{modelo complejo}} - \textit{log-verosimilitud}_{\textit{modelo simple}}).$$

  Bajo la hipótesis nula de que los coeficientes de las variables adicionales son cero, este estadístico sigue aproximadamente una distribución Chi-cuadrado (χ^2) con grados de libertad iguales a la diferencia en el número de parámetros entre ambos modelos (por ejemplo, 1 grado de libertad si se está probando una única variable predictora). Un p-valor bajo ($p < 0.05$) asociado a este test indica que el modelo más complejo se ajusta a los datos significativamente mejor, justificando la inclusión de las variables adicionales. En el contexto de la eliminación hacia atrás, se utiliza para comprobar si la exclusión de una variable empeora el modelo de forma significativa. El LRT es a menudo preferido sobre la prueba de Wald, especialmente en muestras pequeñas, ya que se considera más fiable.

- **p-valor (Significación Estadística)**: Para la inclusión de una variable, se considera su p-valor asociado a la prueba de Wald para el coeficiente de la variable. Un p-valor bajo (inferior a un umbral predefinido, por ejemplo, $p < 0.05$ o $p < 0.10$) indica que la variable es un predictor significativo en presencia de las otras variables ya en el modelo. Para la eliminación, se busca el p-valor más alto (superior a un umbral, por ejemplo, $p > 0.05$ o $p > 0.10$) entre las variables ya en el modelo, indicando que esa variable es la menos significativa y podría ser eliminada sin un impacto sustancial en el ajuste. Recordamos que el estadístico de Wald se calcula de la siguiente manera:

  $$W = \left(\frac{\hat{\beta}_j}{EE(\hat{\beta}_j)} \right)^2,$$

  donde β_j es el coeficiente de una variable X_j de un modelo de regresión logística, $\hat{\beta}_j$ es la estimación del coeficiente y $EE(\hat{\beta}_j)$ es su error estándar. Bajo la hipótesis

nula ($H_0 : \beta_j = 0$), W sigue aproximadamente una distribución Chi-cuadrado con 1 grado de libertad. El p-valor se obtiene a partir de esta estadística.

- **Criterio de Información de Akaike (AIC - Akaike Information Criterion):** El AIC es una medida de la calidad relativa de los modelos estadísticos para un conjunto dado de datos. Ofrece una compensación entre la bondad de ajuste del modelo y la complejidad del modelo (número de parámetros). Un valor de AIC más bajo indica un mejor modelo. Se calcula de la siguiente forma:

$$AIC = -2\textit{log-verosimilitud} + 2k$$

  donde $log - verosimilitud$ es el logaritmo de la función de verosimilitud maximizada del modelo (una mayor $log - verosimilitud$ indica un mejor ajuste), k es el número de parámetros en el modelo (incluyendo el intercepto).
  En la búsqueda stepwise, se busca añadir la variable que produce la mayor disminución en el AIC o eliminar la variable que produce el menor aumento (o incluso una disminución) en el AIC.

- **Criterio de Información Bayesiano (BIC - Bayesian Information Criterion):** Similar al AIC, el BIC también sopesa la bondad de ajuste y la complejidad del modelo, pero impone una penalización más fuerte por el número de parámetros, especialmente en muestras grandes. Un valor de BIC más bajo indica un modelo preferible, tendiendo a seleccionar modelos más parsimoniosos (con menos variables) que el AIC.

$$BIC = -2\textit{log-verosimilitud} + k * \ln(n)$$

  donde n es el número de observaciones en el conjunto de datos.

Selección Hacia Adelante (Forward Selection)

El método de selección hacia adelante, o Forward Selection, se inicia con un modelo ”vacío” o ”nulo”, el cual únicamente incluye el término de intercepto y no contiene ninguna variable predictora.

El proceso de Forward Selection sigue estos pasos:

- **Inicio con Modelo Nulo:** El algoritmo comienza con un modelo que solo contiene el intercepto, sin ninguna variable predictora.

- **Evaluación de Candidatas:** En cada iteración, se evalúan todas las variables candidatas que aún no han sido incorporadas al modelo.

- **Selección de la Mejor Variable:** Se selecciona la variable que, al ser añadida al modelo, produce la mayor mejora en el ajuste. Por ejemplo, si hemos elegido como criterio el p-valor, elegiremos la variable que haga que el p-valor sea inferior a un umbral fijo (suele ser 0.05 o 0.1), y así con los demás criterios.

- **Adición Secuencial:** La variable seleccionada se añade al modelo. Este proceso de adición secuencial continúa.

- **Criterio de Detención:** El proceso se detiene cuando no es posible agregar más variables que cumplan con el criterio de significancia establecido, o hasta que se alcance una regla de detención preespecificada (ej., un número máximo de variables).

Este método es computacionalmente más eficiente que la búsqueda exhaustiva, especialmente con un gran número de predictores, y puede aplicarse incluso cuando el número de predictores supera el número de observaciones. Las decisiones de inclusión son permanentes; una variable añadida no será reevaluada para su posible eliminación en pasos posteriores. Esto puede llevar a un subconjunto de variables que no es globalmente óptimo, ya que la importancia de una variable puede cambiar al incluir otras.

Eliminación Hacia Atrás (Backward Elimination)

El método de eliminación hacia atrás, o Backward Elimination, opera de manera inversa a la selección hacia adelante. Este proceso se inicia con un modelo que incluye todas las variables predictoras candidatas, conocido como el "modelo completo".

El proceso de Backward Elimination sigue estos pasos detallados:

- **Inicio con Modelo Completo:** El algoritmo comienza con un modelo que incluye todas las variables predictoras disponibles.
- **Evaluación de Variables Actuales:** En cada iteración, se evalúan todas las variables que actualmente forman parte del modelo
- **Selección de la Menos Significativa:** Se identifica la variable que demuestra la menor contribución al modelo o la que presenta el p-valor más elevado, lo que indica la menor significancia estadística entre las variables actualmente incluidas. El contraste para la eliminación puede basarse en la probabilidad de un estadístico de la razón de verosimilitud o en el estadístico de Wald.
- **Eliminación Secuencial:** La variable menos significativa se elimina del modelo. Este proceso de eliminación se repite de forma iterativa.
- **Criterio de Detención:** El proceso se detiene hasta que todas las variables que permanecen en el modelo exhiben un p-valor inferior a un umbral de "salida" predeterminado (comúnmente 0.05 o 0.10), o hasta que no queden más variables que cumplan el criterio para ser eliminadas.

Este método requiere que el número de predictores sea menor que el número de observaciones para poder iniciar con el modelo completo, lo que limita su aplicabilidad en escenarios de alta dimensionalidad. La necesidad de ajustar un modelo con todas las variables al principio puede ser computacionalmente intensiva si el número inicial de variables es muy elevado. Al comenzar con todas las variables, puede ofrecer una evaluación inicial más exhaustiva de la importancia de los predictores, lo que puede ser intuitivo para identificar variables que realmente no aportan valor.

Stepwise Bidireccional (Hybrid Stepwise)

La selección stepwise bidireccional, a menudo simplificada como "stepwise", representa una combinación estratégica de los métodos de selección hacia adelante (Forward) y eliminación hacia atrás (Backward).

El proceso de Stepwise Bidireccional sigue estos pasos detallados:

- **Inicio como Forward Selection:** El proceso se inicia de manera similar a la selección hacia adelante, comenzando con un modelo vacío y añadiendo progresivamente la variable más significativa en cada paso.

- **Reevaluación Constante:** Después de cada incorporación de una nueva variable, el algoritmo procede a reevaluar las variables que ya forman parte del modelo.

- **Decisión de Eliminación:** El objetivo de esta reevaluación es determinar si alguna de las variables ya incluidas ha perdido su significancia estadística o si su contribución ha disminuido por debajo de un umbral predefinido, a causa de la inclusión de las nuevas variables. Si se detecta tal situación, la variable en cuestión puede ser eliminada del modelo.

- **Iteración Dinámica:** El algoritmo opera mediante una iteración constante entre las fases de adición y eliminación de variables. Las variables se introducen o se suprimen del modelo en función de si cumplen una serie de condiciones estadísticas previamente establecidas, como umbrales de p-valor o cambios en los criterios de información (AIC/BIC).

- **Criterio de Equilibrio:** Este proceso dinámico continúa hasta que se alcanza un estado de equilibrio: un punto en el que no existen variables fuera del modelo que satisfagan el criterio para ser añadidas, y, simultáneamente, no hay variables dentro del modelo que cumplan el criterio para ser eliminadas.

Este enfoque es considerado uno de los métodos más empleados en la práctica, ya que amalgama las ventajas de los enfoques unidireccionales. Al permitir tanto la adición como la eliminación de variables en cada paso, la regresión stepwise bidireccional se aproxima de manera más efectiva a la selección del "mejor subconjunto" de variables, sin incurrir en las severas limitaciones computacionales de la búsqueda exhaustiva. Busca mitigar la debilidad "codiciosa" de la selección Forward (que nunca elimina una variable una vez añadida) y las limitaciones iniciales de Backward (que requiere un modelo completo desde el principio). Al permitir la reevaluación, es más robusto en la búsqueda de un subconjunto "óptimo" local.

A pesar de sus ventajas en la automatización del proceso de selección, es crucial reconocer una limitación fundamental inherente a todos los métodos stepwise. Estos procedimientos operan de forma puramente algorítmica, basándose solo en criterios estadísticos (como el p-valor o el AIC) derivados de la muestra de datos actual. Este enfoque ignora por completo el conocimiento clínico y la experiencia del investigador.

Como resultado, una variable que es un predictor conocido y de gran relevancia clínica podría ser excluida del modelo final simplemente porque en esa muestra particular no alcanzó el umbral de significancia estadística predefinido. De forma inversa, una variable sin relevancia clínica podría ser incluida por una asociación espuria presente en los datos. Esto puede llevar a modelos que, aunque se ajustan bien a la muestra de desarrollo, son poco robustos, difíciles de generalizar y carecen de credibilidad en la práctica clínica.

Para abordar esta deficiencia, se han propuesto estrategias de modelado que combinan el rigor estadístico con el juicio del experto. Por ejemplo, Collett (2015), en su obra de referencia *Modelling Survival Data in Medical Research*, describe un procedimiento de construcción de modelos que, si bien se asemeja al stepwise en su naturaleza iterativa, está controlado en cada paso por el investigador. En este enfoque, el investigador utiliza

su conocimiento para decidir qué variables son candidatas plausibles, cómo deben introducirse en el modelo (por ejemplo, en bloques lógicos) y utiliza las pruebas estadísticas como una guía para la toma de decisiones, en lugar de una regla automática e inflexible. Este tipo de modelado deliberado asegura que el modelo final no solo sea estadísticamente sólido, sino también clínicamente coherente y relevante.

4.2. Regularización (Shrinkage)

Los métodos de regularización, también conocidos como métodos de contracción (shrinkage), han emergido como una solución poderosa para abordar desafíos comunes como el sobreajuste (overfitting) y la multicolinealidad. A diferencia de las técnicas de selección de variables tradicionales que añaden o eliminan características de forma discreta, los métodos de regularización introducen un término de penalización en la función de costo del modelo, lo que permite encoger los coeficientes de regresión y, en algunos casos, forzarlos a cero. Este enfoque no solo mejora el rendimiento del modelo, sino que también contribuye a su interpretabilidad y estabilidad. Su principal utilidad y ventaja se manifiesta en escenarios de alta dimensionalidad; es decir, cuando el número de variables predictoras candidatas es muy grande, a menudo cercano o incluso superior al número de observaciones. No obstante, se debe tener en cuenta que la elección del 'mejor'subconjunto de variables mediante estos métodos automáticos no siempre es la solución óptima Hanke et al. (2024). Por ello, la selección final siempre debe ser revisada por un profesional en el campo de aplicación para garantizar su relevancia y coherencia.

Nos centramos exclusivamente en los tres métodos de regularización más prominentes: Lasso (L1), Ridge (L2) y Elastic Net. Se explorará en profundidad su fundamento matemático, cómo afectan a los coeficientes del modelo, su capacidad para manejar la multicolinealidad y sus aplicaciones específicas en la regresión logística.

Regresión Lasso (Regularización L1)

La regresión Lasso, acrónimo de "Least Absolute Shrinkage and Selection Operator", es una técnica de regularización que se ha vuelto indispensable en el aprendizaje automático y el modelado estadístico. Su objetivo principal es lograr un equilibrio entre la simplicidad del modelo y la precisión predictiva, especialmente en escenarios con alta dimensionalidad o multicolinealidad.
Lasso introduce un término de penalización basado en el valor absoluto de los coeficientes de regresión a la función de costo tradicional (que para la regresión logística es la log-verosimilitud negativa).
La función de costo penalizada para la regresión logística con regularización Lasso se define como:

$$l_{Lasso}(\beta) = \sum_{i=1}^{n}\left(\ln\Big(1+\exp(\alpha + x_i^t\beta\Big) - y_i(\alpha + x_i^t\beta)\right) + \lambda\sum_{j=1}^{p}|\beta_j|,$$

donde $\sum_{i=1}^{n}\left(\ln\Big(1+\exp(\alpha + x_i^t\beta\Big) - y_i(\alpha + x_i^t\beta)\right)$ es la log-verosimilitud negativa (o función de pérdida de entropía cruzada binaria) para la regresión logística, α es el término de intercepción, $x_i^t\beta$ representa la combinación lineal de las variables predictoras y sus coeficientes, λ es el parámetro de sintonización o de regularización, un valor no negativo que controla la cantidad de penalización aplicada y $\lambda\sum_{j=1}^{p}|\beta_j|$ es la norma L1 de los coeficientes, que es la suma de los valores absolutos de los coeficientes de regresión (β_j).
El objetivo de Lasso es **minimizar** esta función de costo penalizada.
El efecto más distintivo de la penalización L1 es su capacidad para encoger algunos coeficientes a cero. Esto significa que las variables independientes correspondientes a esos coeficientes se eliminan efectivamente del modelo. Esta característica convierte a Lasso en una poderosa herramienta para la selección automática de características, lo que resulta en modelos más simples y esparcidos (con menos variables).
La principal ventaja de la regresión Lasso, y la razón de su popularidad, es su capacidad intrínseca para realizar una selección automática de características, lo que la convierte en una herramienta especialmente potente en escenarios de alta dimensionalidad. Al poder encoger los coeficientes de las variables menos importantes exactamente a cero, simplifica el modelo y, al hacerlo, reduce eficazmente el riesgo de sobreajuste. Sin embargo, esta capacidad de selección no está exenta de limitaciones. Su principal inconveniente surge cuando se enfrenta a grupos de predictores altamente correlacionados, situación en la que tiende a seleccionar una variable del grupo de forma arbitraria, lo que puede generar inestabilidad en el modelo. Además, la penalización introduce un sesgo en los coeficientes de las variables restantes y no siempre garantiza la identificación del conjunto "verdadero" de predictores bajo ciertas condiciones.

Regresión Ridge (Regularización L2)

La regresión Ridge, también conocida como regularización L2 o regularización de Tikhonov, es otra técnica de regularización diseñada para abordar el sobreajuste y, de manera crucial, la multicolinealidad en los modelos de regresión. Ridge añade un término de penalización basado en el cuadrado de los coeficientes de regresión a la función de costo.

Para la regresión logística, la función de costo penalizada con regularización Ridge se

formula como:

$$l_{Ridge}(\beta) = \sum_{i=1}^{n}\left(\ln\Big(1+\exp(\alpha + x_i^t\beta\Big) - y_i(\alpha + x_i^t\beta)\right) + \frac{\lambda}{2}\sum_{j=1}^{p}\beta_j^2,$$

donde los parámetros son los mismos que los de Lasso, con la diferencia de que $\sum_{j=1}^{p}\beta_j^2$ es la norma L2 de los coeficientes.
A diferencia de Lasso, la penalización L2 encoge los coeficientes hacia cero, pero rara vez los hace exactamente cero. Esto implica que Ridge no realiza selección de características automática al eliminar variables del modelo. En su lugar, distribuye la influencia entre todas las características, lo que es particularmente útil cuando hay una fuerte multicolinealidad entre muchas covariables con efectos potencialmente pequeños.
A diferencia de Lasso, la regresión Ridge está diseñada principalmente para abordar el problema de la multicolinealidad. Al penalizar la suma de los coeficientes al cuadrado, Ridge distribuye la influencia entre las variables correlacionadas, lo que resulta en estimaciones de coeficientes más estables y una reducción de la varianza del modelo, mejorando así su capacidad de generalización y evitando el sobreajuste. La contrapartida de esta estabilidad es su principal limitación: Ridge no realiza selección de características, ya que encoge los coeficientes hacia cero pero rara vez los anula. Esto significa que el modelo final conserva todas las variables originales, lo que puede hacerlo menos interpretable que un modelo simplificado por Lasso.

Regularización Elastic Net

Elastic Net es un método de regularización que busca combinar las fortalezas de Lasso (L1) y Ridge (L2), superando sus limitaciones individuales. Fue desarrollado para abordar la inestabilidad de Lasso con variables correlacionadas y la falta de selección de características de Ridge.
Aunque la fórmula explícita de la función de costo penalizada para la regresión logística no se proporciona en todos los fragmentos, se entiende que combina la log-verosimilitud negativa con ambos términos de penalización L1 y L2. La forma general de la penalización combinada es:

$$\lambda\left(\alpha\sum_{j=1}^{p}|\beta_j| + \frac{1}{2}(1-\alpha)\sum_{j=1}^{p}\beta_j^2\right).$$

Observamos que cuando $\alpha = 0$, Elastic Net se reduce a Ridge (solo penalización L2), y cuando $\alpha = 1$, se reduce a Lasso (penalización L1).
Esta flexibilidad permite un control preciso sobre el compromiso entre la esparsidad y la estabilidad de los coeficientes.

Elastic Net hereda la capacidad de Lasso para realizar selección de características (gracias al término L1), lo que significa que puede forzar algunos coeficientes a cero y, por lo tanto, eliminar variables del modelo.

Crucialmente, Elastic Net también incorpora el ”efecto de agrupación” de Ridge. Esto significa que tiende a seleccionar grupos de variables correlacionadas juntas, en lugar de elegir arbitrariamente una de ellas como lo hace Lasso. Esto asegura que los predictores importantes sean menos propensos a ser eliminados inadvertidamente, lo que lleva a un modelo más completo y estable.
Elastic Net es particularmente robusto cuando se trata de numerosos predictores correlacionados. La penalización L2 en Elastic Net aborda la multicolinealidad al encoger los coeficientes de las variables altamente correlacionadas de manera similar, en lugar de que

Lasso elija una arbitrariamente y descarte las demás. Esto lo hace más estable y fiable en presencia de multicolinealidad severa.
La regularización Elastic Net hereda la capacidad de Lasso para realizar selección de características al poder anular coeficientes (gracias a la penalización L1), pero también incorpora el "efecto de agrupación" de Ridge (gracias a la penalización L2). Este efecto es particularmente útil, ya que le permite manejar la multicolinealidad de forma robusta, seleccionando grupos de variables correlacionadas en conjunto en lugar de elegir una de forma arbitraria como haría Lasso. Esta flexibilidad y robustez, sin embargo, conllevan una mayor complejidad en su implementación, ya que requiere la sintonización de dos hiperparámetros (λ y α) en lugar de uno solo.

5 Categorización de variables cuantitativas

En la construcción de índices pronóstico, la categorización de variables cuantitativas es un paso metodológico frecuente y pragmático. Aunque este proceso de transformar datos continuos en un conjunto de categorías discretas puede implicar una cierta pérdida de información, su principal justificación en este contexto es la eficiencia y simplicidad que aporta a la hora de construir la herramienta final: el score o la "calculadora" clínica.
En lugar de requerir que un médico introduzca un valor exacto en una fórmula compleja, la categorización permite asignar una puntuación de riesgo fija a cada grupo (por ejemplo, "$Edad > 75$ *años* $= 3$ *puntos*"). Esto convierte el cálculo de riesgo en una simple suma de puntos, facilitando una evaluación rápida y aplicable en la práctica clínica diaria.

5.1. Métodos de Binning No Supervisados

Los métodos de binning no supervisados son técnicas de discretización que no requieren una variable objetivo para definir los límites de los bins. Se basan únicamente en la distribución de la variable continua en sí.

- **Binning de Ancho Igual (Equal-Width Binning)** El binning de ancho igual, también conocido como binning de distancia igual, es una técnica de discretización que divide el rango completo de una variable continua en un número especificado de intervalos o "bins" de idéntico tamaño o ancho. Es uno de los métodos más sencillos y directos para categorizar datos numéricos.
  El ancho de cada bin se determina mediante la siguiente fórmula:

  $$bin_{width} = \frac{\text{máx}(X) - \text{mín}(X)}{bins},$$

  donde bin_{width} representa el ancho uniforme de cada bin, $\text{máx}(X)$, $\text{mín}(X)$ son el máximo y el mínimo valor observado de la variable que se está discretizando, y $bins$ es el número de bins deseados, definido por el autor.
  El principal atractivo del binning de ancho igual reside en su simplicidad de implementación y su facilidad de comprensión, lo que lo convierte en un método directo para categorizar datos numéricos. Es particularmente útil para distribuir datos de manera uniforme en visualizaciones como histogramas, especialmente cuando el rango de la variable es consistente y no presenta sesgos marcados.
  No obstante, su mayor debilidad se manifiesta precisamente cuando se enfrenta a datos que no son uniformes. Debido a que los puntos de corte son fijos e ignoran

la distribución de los datos, este método es muy sensible a la presencia de valores atípicos y distribuciones sesgadas, lo que puede generar una distribución de observaciones muy desigual entre los bins. Esto a menudo resulta en la creación de intervalos con muy pocas observaciones o incluso vacíos, lo cual puede ser problemático para cualquier análisis estadístico posterior. Por tanto, es fundamental entender que la "igualdad en el ancho" del intervalo numérico no se traduce en una distribución equitativa de las observaciones, un desequilibrio que puede presentar desafíos significativos en la modelización.
La denominación "ancho igual" podría sugerir una equidad inherente o una ausencia de sesgo en la distribución de los datos. Sin embargo, su aplicación práctica a menudo revela un desequilibrio significativo en la distribución de los puntos de datos entre los bins, especialmente cuando se trabaja con datos sesgados o valores atípicos (Han et al., 2012). Esto significa que, si bien el rango numérico de cada bin es idéntico, el número de observaciones dentro de cada bin puede variar drásticamente. Esta discrepancia subraya que la igualdad en la amplitud del intervalo no se traduce necesariamente en una distribución equitativa de las observaciones, lo que puede generar desafíos prácticos en el análisis y la modelización.

- **Binning de Frecuencia Igual (Equal-Frequency Binning / Quantile Binning)** El binning de frecuencia igual, también conocido como binning por cuantiles, es una técnica de discretización que divide el rango de una variable continua en un número especificado de intervalos o "bins" de tal manera que cada bin contiene aproximadamente el mismo número de observaciones o puntos de datos. Este método es particularmente útil para manejar datos sesgados, ya que asegura una distribución equilibrada de los datos entre los bins, evitando bins vacíos o con muy pocas observaciones.
Los puntos de corte en el binning de frecuencia igual se determinan dinámicamente utilizando cuantiles (por ejemplo, medianas, cuartiles, deciles, percentiles) de la distribución de los datos.

- **Binning Basado en Clustering (K-Means Binning)** El binning basado en clustering, como el K-Means, es una técnica de discretización que agrupa los valores de una variable continua en bins basándose en su similitud intrínseca, utilizando algoritmos de clustering. Este método es particularmente efectivo cuando la distribución de los datos es compleja o presenta agrupaciones naturales que no serían capturadas por métodos más simples. Se realiza en los siguientes pasos:

  - **Clustering de los datos:** Se aplica el algoritmo K-Means directamente a la variable continua que se desea discretizar. K-Means busca dividir n observaciones en k clusters, donde cada observación pertenece al cluster con la media (centroide) más cercana.
  - **Definición de bins por clusters:** Una vez que el algoritmo K-Means converge, identifica k centroides de cluster y asigna cada punto de datos a uno de estos k clusters. Cada uno de estos clusters forma un "bin", y los valores dentro de un cluster dado se consideran similares entre sí, por lo que se agrupan en el mismo bin.
  - **Asignación de identificadores de bin:** Después de formar los clusters, cada punto de datos (valor continuo original) se reemplaza con un identificador

que corresponde al bin (cluster) al que pertenece. Esto transforma los valores continuos en valores discretos y categóricos.

A diferencia de los métodos de ancho o frecuencia igual, el binning K-Means no tiene una fórmula simple para los límites de los bins, ya que estos se derivan de la estructura de clustering de los datos. Este enfoque es beneficioso para conjuntos de datos donde la distribución subyacente de la variable continua es compleja y no se captura fácilmente con métodos de intervalo fijo o de recuento igual.

5.2. Métodos de Binning Supervisados

A diferencia de los métodos no supervisados, las técnicas de binning supervisado utilizan la información de la variable objetivo (la variable dependiente) para guiar la creación de los grupos o bins (**?**). El objetivo estadístico de estos métodos es particionar el rango de una variable predictora continua en un conjunto de categorías que sean internamente lo más homogéneas posible con respecto a la variable objetivo, y al mismo tiempo, lo más diferentes posible entre ellas. Esto se logra buscando los "puntos de corte" óptimos que maximizan la relación predictiva con el resultado de interés.

Binning Basado en Árboles de Decisión (Decision Tree-Based Binning)

Un enfoque muy extendido para realizar este binning supervisado es el que se basa en algoritmos de árboles de decisión. El procedimiento consiste en identificar de forma iterativa los mejores puntos de corte para una variable continua, utilizando una regla de decisión estadística para evaluar cada posible división. Aunque existen varias reglas, el principio subyacente es siempre el mismo: encontrar la división que maximice la "pureza" de los nodos hijos. Las reglas de decisión más comunes son:

- **Reducción de la Varianza (Test F de $ANOVA$):** Este es uno de los criterios más utilizados en estadística. El algoritmo busca el punto de corte que maximiza la varianza entre los grupos resultantes y minimiza la varianza dentro de cada grupo. Esto es conceptualmente idéntico a realizar un test F de $ANOVA$ en cada posible punto de corte y seleccionar la división que produce el valor F más alto, indicando la mayor separación entre las medias de la variable objetivo de los grupos.

- **Índice de Concentración de Gini:** Originario de la econometría para medir la desigualdad de la riqueza, el índice de Gini se utiliza aquí para medir el grado de "concentración" o pureza de la variable objetivo en cada grupo. Un índice de Gini de 0 representa una pureza perfecta (todos los casos del grupo pertenecen a la misma clase de la variable objetivo), mientras que un valor más alto indica una mayor mezcla o "impureza". El algoritmo elige el corte que resulta en la menor impureza de Gini ponderada en los grupos resultantes.

- **Ganancia de Información (Entropía):** Basado en la teoría de la información, este criterio mide la reducción en la incertidumbre (entropía) sobre la variable objetivo después de realizar una división. El objetivo es encontrar el punto de corte que proporcione la mayor ganancia de información, lo que equivale a crear los subconjuntos más homogéneos

Proceso Práctico de Determinación de Puntos de Corte En la práctica, especialmente en la construcción de scorecards de riesgo, la aplicación de estos árboles no se hace en un solo paso. A menudo se sigue un procedimiento de dos etapas conocido como Fine and Coarse Classing:

- **Clasificación Fina (Fine Classing):** Primero, la variable continua se divide en un número relativamente grande de intervalos iniciales (10-20), a menudo usando cuantiles para asegurar un número mínimo de casos en cada uno.
- **Clasificación Gruesa (Coarse Classing):** Luego, se procede a combinar los intervalos adyacentes de la clasificación fina. Usando un criterio estadístico (como la prueba Chi-cuadrado para comparar la "tasa de eventos" entre bins contiguos), se fusionan aquellos que no son significativamente diferentes. Este proceso de agrupación reduce el número de categorías finales, simplificando el modelo y asegurando que cada categoría sea robusta y tenga poder predictivo.

Binning Óptimo con Weight of Evidence (WOE) e Information Value (IV)

El binning óptimo, a menudo combinado con la transformación Weight of Evidence (WOE) y el cálculo de Information Value (IV), es una técnica de binning supervisada ampliamente utilizada en modelos de riesgo de crédito y regresión logística. Su objetivo es agrupar variables continuas de manera que se maximice su poder predictivo para una variable objetivo binaria.

Weight of Evidence (WOE):

WOE transforma variables categóricas o continuas binned en una forma más predictiva, estableciendo una relación directa entre las variables transformadas y la variable objetivo (ej., incumplimiento o no incumplimiento). Ayuda a crear relaciones monótonas entre las variables independientes y la dependiente, lo cual es deseable para la regresión logística. Para cada bin k, el WOE se calcula como el logaritmo natural de la razón entre el porcentaje de no-eventos y el porcentaje de eventos en ese bin:

$$WOE_k = \ln\left(\frac{\%\ \textit{de no-eventos en el bin } k}{\%\ \textit{de eventos en el bin } k}\right).$$

Un WOE negativo indica que la proporción de eventos es mayor para ese atributo que la proporción general, lo que sugiere un mayor riesgo. Los valores de WOE deben ser distintos y mostrar una relación monótona (creciente o decreciente) a través de los bins para indicar un binning exitoso.

Information Value (IV)

IV es una métrica utilizada para medir el poder predictivo de una variable y ayuda a clasificar las variables según su importancia en un modelo de clasificación binaria. El IV se calcula sumando el producto de la diferencia entre el porcentaje de no-eventos y el porcentaje de eventos, y el WOE para cada bin:

$$IV = \sum_{k=1}^{K} (\%\ \textit{de no-eventos en el bin } k - \%\ \textit{de eventos en el bin } k) WOE_k,$$

donde K es el número de bins. Valores de IV más altos indican un mayor poder predictivo de la variable. Las variables con IV bajo (ej., menos de 0.02) pueden considerarse no útiles para la predicción, mientras que valores entre 0.1 y 0.3 sugieren un poder predictivo moderado, y valores superiores a 0.3 un poder predictivo fuerte.

Proceso de Binning con WOE/IV

- **Binning inicial**: Las variables continuas se dividen primero en un número inicial de bins (ej., 10 o 20).
- **Cálculo de WOE e IV:** Se calcula el WOE y el IV para cada bin.
- **Agregación de bins:** Los bins con valores de WOE similares se pueden combinar para simplificar el modelo y mejorar la estabilidad y la interpretabilidad.
- **Transformación:** Los valores originales de la variable se reemplazan con sus respectivos valores de WOE para ser utilizados como predictores en el modelo de regresión logística.

Capítulo 2

Validación del Modelo Pronóstico

Una vez se ha construido el modelo predictivo final, es imprescindible evaluar si funciona correctamente antes de considerar su implementación o su traducción a un score clínico. Este proceso, conocido como validación, tiene como objetivo cuantificar el rendimiento predictivo del modelo para asegurar que sus predicciones son fiables y generalizables a nuevos pacientes.

Un modelo que no ha sido rigurosamente validado corre el riesgo de estar sobreajustado a los datos con los que fue creado, lo que limitaría su utilidad en la práctica clínica real.

Por lo tanto, en esta sección se detallarán los dos pilares fundamentales para evaluar el rendimiento de un modelo de regresión logística: su capacidad de discriminación (¿distingue bien entre pacientes con y sin el evento?) y su calibración (¿sus predicciones de riesgo se ajustan a la realidad?). Asimismo, se abordarán las estrategias de validación interna y externa, pasos cruciales para confirmar la robustez del modelo antes de proceder a su simplificación en un score pronóstico.

1 Evaluación del Rendimiento

La evaluación del rendimiento de un modelo pronóstico de regresión logística se sustenta en dos dimensiones complementarias y esenciales: la discriminación y la calibración. La discriminación se refiere a la capacidad del modelo para diferenciar correctamente entre los sujetos que experimentarán el evento de interés y aquellos que no. Por otro lado, la calibración evalúa la concordancia entre las probabilidades de evento predichas por el modelo y las tasas de evento que se observan realmente en la población. Ambas dimensiones deben ser evaluadas para obtener una imagen completa de la utilidad del modelo.

1.1. Discriminación

La discriminación es la habilidad de un modelo pronóstico para asignar, de manera consistente, puntuaciones de riesgo más elevadas a los individuos que subsecuentemente desarrollan el evento de interés, en comparación con aquellos que no lo desarrollan. En esencia, mide cuán bien el modelo puede "acertar el futuro" o "discernir" entre los diferentes desenlaces posibles para los individuos.

La Curva ROC La curva ROC es una herramienta gráfica fundamental que visualiza la capacidad de discriminación de un modelo de clasificación binaria a través de todo el

espectro de posibles umbrales de decisión. Se construye representando la Tasa de Verdaderos Positivos (TVP), también conocida como Sensibilidad, en el eje Y, frente a la Tasa de Falsos Positivos (TFP), que es igual a (1 - Especificidad), en el eje X. Cada punto de la curva corresponde a un par (TFP, TVP) obtenido al variar el umbral de probabilidad utilizado para clasificar una observación como positiva o negativa.
Las métricas clave son:

- Sensibilidad (TVP): Proporción de individuos que experimentan el evento y son correctamente identificados por el modelo. Se calcula como $TVP = \frac{VP}{VP+FN}$, donde VP son los verdaderos positivos y FN los falsos negativos.

- Especificidad (Esp): Proporción de individuos que no experimentan el evento y son correctamente identificados por el modelo. Se calcula como $Esp = \frac{VN}{VN+FP}$ donde VN son los verdaderos negativos y FP son los falsos positivos.

- Tasa de Falsos Positivos (TFP): Proporción de individuos que no experimentan el evento pero son incorrectamente clasificados como positivos por el modelo. Se calcula como $TFP = 1 - Esp$.

El proceso de construcción implica ordenar las probabilidades de evento predichas por el modelo para cada individuo en la muestra de evaluación. Luego, para cada valor único de probabilidad predicha (o para un conjunto de umbrales predefinidos), se calculan la TVP y la TFP correspondientes, generando los puntos que conforman la curva.
La forma de la curva ROC proporciona información visual directa sobre el rendimiento discriminatorio del modelo. Una curva que se desplaza hacia el vértice superior izquierdo del gráfico, aproximándose al punto (0,1) (TFP=0, TVP=1), indica una mejor capacidad de discriminación. Un modelo que alcanzara este punto sería un clasificador perfecto, capaz de distinguir sin error entre los que experimentarán el evento y los que no. Por el contrario, la línea diagonal que va desde el punto (0,0) hasta el (1,1) representa un modelo sin capacidad de discriminación alguna, equivalente a una predicción realizada al azar (por ejemplo, lanzando una moneda). La curva ROC permite visualizar el compromiso inherente (trade-off) entre la sensibilidad y la especificidad a medida que se modifica el umbral de decisión; para aumentar la sensibilidad (capturar más verdaderos positivos), a menudo se debe aceptar un aumento en la tasa de falsos positivos (una disminución en la especificidad).

El área bajo la curva ROC o estadístico C El Área Bajo la Curva ROC (AUC), también conocida como estadístico C (especialmente en contextos de regresión logística y supervivencia), es una medida escalar única que resume el rendimiento discriminatorio global del clasificador a través de todos los posibles umbrales de decisión. El AUC tiene una interpretación probabilística intuitiva: representa la probabilidad de que el modelo asigne una puntuación de riesgo (o probabilidad predicha) más alta a un individuo elegido al azar que experimenta el evento, en comparación con un individuo elegido al azar que no lo experimenta. Aunque no existe una fórmula analítica simple para el AUC directamente a partir de los conteos de VP/FP, se calcula integrando la función ROC. Numéricamente, esto se realiza comúnmente utilizando la regla trapezoidal sobre los puntos que definen la curva ROC.
El valor del AUC varía entre 0.0 y 1.0, aunque en la práctica, para modelos con alguna capacidad predictiva, se sitúa entre 0.5 y 1.0.

- AUC = 1.0. Discriminación perfecta. El modelo asigna puntuaciones más altas a todos los individuos que experimentan el evento en comparación con todos los que no lo experimentan.
- AUC = 0.5: Discriminación nula, equivalente al azar. El modelo no tiene capacidad para distinguir entre los dos grupos. Un modelo con un AUC inferior a 0.5 indica un rendimiento peor que el azar; en tales casos, invertir las predicciones del modelo podría mejorar su rendimiento por encima de 0.5.

Cuadro 2.1: Niveles de discriminación según el valor AUC.

Rango del Valor AUC	**Nivel de Discriminación**
0.90 - 1.00	Excelente
0.80 - 0.89	Muy Bueno
0.70 - 0.79	Bueno / Aceptable
0.60 - 0.69	Regular / Suficiente
0.50 - 0.59	Pobre / No útil
< 0.50	Peor que el azar

El AUC es una métrica ampliamente utilizada debido a varias ventajas: es una medida global del rendimiento discriminatorio que es independiente del umbral de decisión elegido, lo que facilita la comparación objetiva entre diferentes modelos. Además, tiende a ser una medida robusta, especialmente en conjuntos de datos con desequilibrio de clases (donde una clase es mucho más frecuente que la otra).

Sin embargo, el AUC también tiene limitaciones. Su principal limitación es que no evalúa la calibración del modelo; es decir, no informa si las probabilidades predichas por el modelo son numéricamente correctas. Un modelo puede tener una excelente capacidad de discriminación (AUC alto) pero estar mal calibrado, asignando probabilidades sistemáticamente demasiado altas o demasiado bajas. En situaciones de desequilibrio de clases extremo, métricas complementarias como las curvas de precisión-exhaustividad (precision-recall curves) pueden ofrecer una perspectiva más matizada del rendimiento.

Es fundamental comprender que el AUC es, en esencia, una medida de la capacidad del modelo para ordenar correctamente a los individuos según su riesgo, no de la exactitud de la magnitud de la probabilidad predicha. Un modelo puede lograr un AUC de 1.0 (ordenamiento perfecto) pero, al mismo tiempo, predecir probabilidades que están sistemáticamente desviadas de las observadas (mala calibración). Esta distinción subraya por qué la discriminación y la calibración son aspectos complementarios y ambos deben evaluarse.

Aunque el AUC es independiente del umbral, la curva ROC puede ayudar a informar la elección de un umbral de decisión óptimo si se deben considerar los costos relativos de los falsos positivos y los falsos negativos en un contexto clínico específico. Sin embargo, el AUC por sí mismo no determina este umbral.

1.2. Calibración

La calibración de un modelo pronóstico se refiere al grado de acuerdo entre las probabilidades de evento predichas por el modelo y las frecuencias de evento que se observan realmente en la población, a lo largo de todo el espectro de predicciones. Un modelo se considera bien calibrado si, por ejemplo, para el grupo de individuos a los que el modelo

asigna una probabilidad de evento del 20 %, aproximadamente el 20 % de ellos efectivamente experimentan el evento. La calibración es crucial porque, mientras la discriminación indica si el modelo puede distinguir entre bajo y alto riesgo, la calibración indica si las estimaciones de riesgo del modelo son numéricamente fiables (Huang et al., 2020).

Test de Hosmer-Lemeshow(H-L) El test de Hosmer-Lemeshow Hosmer and Lemeshow (1980) es una prueba estadística de bondad de ajuste diseñada específicamente para modelos de regresión logística. Su propósito es evaluar si las tasas de eventos observadas en subgrupos de la población (formados según el riesgo predicho) concuerdan con las tasas de eventos esperadas según las predicciones del modelo. Típicamente, estos subgrupos se forman dividiendo a los individuos en deciles de riesgo predicho.
El procedimiento para calcular el estadístico de H-L implica los siguientes pasos:

1. Ordenar a los sujetos según las probabilidades de riesgo predichas por el modelo, de menor a mayor.

2. Dividir a los sujetos en (G) grupos, comúnmente (G=10) (deciles), aunque el número de grupos puede variar. Debido a empates en las probabilidades predichas, el número de sujetos en cada grupo puede no ser idéntico.

3. Para cada grupo (g = 1,..., G):

   - Calcular el número de eventos observados (O_{1g}) y el número de no-eventos observados (O_{0g}). El total de observaciones en el grupo es $N_g = O_{1g} + O_{0g}$.
   - Calcular el número de eventos esperados (E_{1g}) sumando las probabilidades predichas para todos los individuos en ese grupo: $E_{1g} = \sum_{i \ni g} p_i$, donde p_i es la probabilidad predicha para el individuo i en el grupo g
   - Calcular el número de no-eventos esperados (E_{0g}) como $E_{0g} = \sum_{i \ni g} 1 - p_i = N_g - E_{1g}$.

4. El estadístico de Hosmer-Lemeshow (H) se calcula mediante la fórmula:

$$H = \sum_{g=1}^{G} \left(\frac{(O_{1g} - E_{1g})^2}{E_{1g}} + \frac{(O_{0g} - E_{0g})^2}{E_{0g}} \right).$$

   Esta fórmula compara las frecuencias observadas con las esperadas tanto para los eventos como para los no-eventos en cada grupo. Bajo la hipótesis nula de buen ajuste, el estadístico H sigue aproximadamente una distribución Chi-cuadrado (χ^2) con $G - 2$ grados de libertad.

- La hipótesis nula (H_0) del test de Hosmer-Lemeshow es que el modelo está bien calibrado, lo que implica que no existe una diferencia significativa entre las frecuencias de eventos observadas y las esperadas a través de los grupos de riesgo definidos.

- Un p-valor resultante que sea mayor que el nivel de significancia preestablecido (comúnmente $\alpha = 0.05$) sugiere que no hay evidencia suficiente para rechazar la hipótesis nula. En este caso, se concluye que el modelo muestra un buen ajuste a los datos en términos de calibración.

- Por el contrario, un p-valor menor que α indica que se rechaza la hipótesis nula, lo que sugiere una falta de ajuste del modelo, es decir, una mala calibración. Esto implica que las probabilidades predichas por el modelo no se corresponden adecuadamente con las frecuencias observadas de eventos.

A pesar de su uso extendido, el test de H-L presenta varias limitaciones importantes que cuestionan su fiabilidad como única medida de calibración. Su resultado es muy sensible tanto al número de grupos (G) en que se dividen los datos como al tamaño de la muestra. Este último punto es un problema de doble filo: en muestras pequeñas, el test puede carecer de la potencia necesaria para detectar una mala calibración real, mientras que en muestras muy grandes, puede resultar estadísticamente significativo incluso cuando las discrepancias entre los valores observados y esperados son mínimas y clínicamente irrelevantes. Además, otra de sus deficiencias clave es que el test H-L no proporciona información sobre dónde o cómo el modelo está mal calibrado (es decir, si subestima o sobreestima el riesgo y en qué rango de probabilidad lo hace), ofreciendo únicamente una evaluación global. Precisamente por estas limitaciones, directrices como la declaración TRIPOD (Collins et al., 2015) desaconsejan el uso exclusivo de los p-valores de esta prueba, recomendando siempre su complementación con métodos gráficos.

Gráficos de Calibración (Calibration Plots) Los gráficos de calibración ofrecen una evaluación visual directa de la calibración de un modelo. Su construcción implica :

1. Agrupar a los sujetos en cuantiles (por ejemplo, deciles o quintiles) basados en las probabilidades de evento predichas por el modelo.

2. Para cada uno de estos grupos:

   - Calcular la media de las probabilidades predichas por el modelo.
   - Calcular la proporción observada de eventos (es decir, la tasa real de eventos en ese grupo).

3. Representar gráficamente la proporción observada de eventos (generalmente en el eje Y) frente a la media de las probabilidades predichas (generalmente en el eje X) para cada grupo.

La interpretación de un gráfico de calibración se centra en la proximidad de los puntos graficados a la línea diagonal de identidad, que representa la calibración perfecta. Un modelo se considera idealmente calibrado cuando los puntos se alinean estrechamente a lo largo de esta diagonal, lo que significa que si el modelo predice, en promedio, una probabilidad de p para un grupo, la proporción observada de eventos en ese grupo es también p.

Por el contrario, las desviaciones sistemáticas de esta línea indican una mala calibración. Específicamente, si los puntos se sitúan consistentemente por encima de la diagonal, el modelo tiende a subestimar el riesgo, ya que las probabilidades predichas son menores que las observadas. A la inversa, si los puntos caen por debajo de la diagonal, el modelo sobreestima el riesgo. De este modo, el gráfico permite una evaluación visual detallada de la calibración a lo largo de todo el rango de probabilidades, identificando las regiones específicas donde el modelo falla. Para ayudar a juzgar si estas desviaciones son estadísticamente significativas, a menudo se superponen intervalos de confianza para las proporciones observadas.

La calibración es un aspecto del rendimiento del modelo que es distinto e igualmente importante que la discriminación. Un modelo puede tener una excelente capacidad discriminatoria (un AUC alto) pero estar mal calibrado, lo que llevaría a decisiones clínicas subóptimas si se confía en la magnitud absoluta de las probabilidades predichas. Por ejemplo, un modelo que discrimina perfectamente entre pacientes de bajo y alto riesgo pero predice probabilidades del 1 % y 2 % cuando las tasas reales son del 10 % y 20 %, respectivamente, estaría mal calibrado a pesar de su perfecta discriminación. Por ello, ambas métricas deben evaluarse conjuntamente.

1.3. Otras métricas relevantes

Además del AUC y las herramientas de calibración como el test de H-L y los gráficos de calibración, existen otras métricas que pueden ofrecer información valiosa sobre el rendimiento de un modelo pronóstico.

Brier Score: Medida de la precisión global del pronóstico El Brier Score (BS) es una medida del error cuadrático medio entre las predicciones probabilísticas y los resultados observados. Para un resultado binario, se calcula como:

$$BS = \frac{1}{N}\sum_{t=1}^{N}(f_t - o_t)^2,$$

donde N es el número total de observaciones, f_t es la probabilidad pronosticada por el modelo para la observación t, y o_t es el resultado observado para la observación t (codificado como 1 si el evento ocurrió y 0 si no ocurrió).

El Brier Score varía entre 0 y 1 para predicciones binarias. Un valor de 0 indica una predicción perfecta (todas las probabilidades predichas coinciden exactamente con los resultados observados). Un valor más alto indica una peor precisión global. Como punto de referencia, un modelo que asigna consistentemente una probabilidad de 0.5 a cada evento (equivalente a no tener información) tendría un Brier Score de 0.25. El Brier Score es una ”proper scoring rule”, lo que significa que alcanza su valor mínimo solo cuando las probabilidades predichas por el modelo coinciden con las verdaderas probabilidades subyacentes del evento. De forma interesante, el Brier Score puede descomponerse en componentes que reflejan la fiabilidad (calibración) y la resolución (relacionada con la discriminación) del modelo, ofreciendo una visión más profunda de sus fuentes de error.

Análisis de Curvas de Decisión (DCA): Evaluación del beneficio clínico neto El Análisis de Curvas de Decisión (DCA) Vickers and Elkin (2006) es un método para evaluar la utilidad clínica de un modelo pronóstico al cuantificar el ”beneficio neto” a través de un rango de ”probabilidades umbral” (P_t). La probabilidad umbral (P_t) representa el nivel de riesgo a partir del cual un paciente o un médico considerarían que los beneficios de una intervención superan sus daños o costos, y por lo tanto, optarían por la intervención. DCA ayuda a determinar si un modelo predictivo ofrece un mayor beneficio clínico en comparación con estrategias alternativas simples, como tratar a todos los pacientes o no tratar a ninguno, o en comparación con otros modelos.

El beneficio neto se calcula como:

$$\text{Beneficio Neto (BN)} = \frac{VP}{N} - \frac{FP}{N}\frac{P_t}{1-P_t}.$$

Esta fórmula pondera los verdaderos positivos (beneficio de tratar correctamente) contra los falsos positivos (daño de tratar innecesariamente), donde la ponderación depende de la probabilidad umbral P_t.
En un gráfico de DCA, se representan las curvas de beneficio neto para el modelo de interés y para las estrategias de referencia (tratar a todos, no tratar a ninguno) en función de un rango de probabilidades umbral. El modelo que muestra el mayor beneficio neto dentro de un rango clínicamente relevante de probabilidades umbral se considera el más útil desde una perspectiva de toma de decisiones.

El Brier Score proporciona una medida agregada que combina aspectos de discriminación y calibración. Sin embargo, al ser una cifra única, puede enmascarar deficiencias específicas en una u otra de estas dimensiones. Por otro lado, el Análisis de Curvas de Decisión introduce explícitamente el concepto de utilidad clínica al incorporar las consecuencias de las decisiones basadas en el modelo y las preferencias implícitas en la elección de un umbral de intervención. La elección entre estas métricas (o su uso conjunto) debe estar alineada con el propósito final del modelo. Si el objetivo principal es la precisión general de las probabilidades predichas, el Brier Score es una métrica muy informativa. Si, en cambio, el modelo se va a utilizar para guiar decisiones clínicas específicas que implican umbrales de acción, el DCA ofrece una evaluación más directa de su valor práctico.

2 Estrategias de validación

Una vez que se han establecido las métricas para evaluar el rendimiento de un modelo pronóstico (discriminación y calibración), el siguiente paso crucial es aplicar estrategias de validación que proporcionen una estimación realista de cómo se comportará el modelo cuando se enfrente a datos nuevos, no vistos durante su desarrollo. Calcular estas métricas únicamente en la muestra de desarrollo original proporciona lo que se conoce como ”rendimiento aparente”, que suele ser excesivamente optimista debido al sobreajuste. Las estrategias de validación se dividen principalmente en validación interna y validación externa.

2.1. Validación Interna

La validación interna agrupa un conjunto de técnicas que utilizan la muestra de datos original empleada para el desarrollo del modelo con el fin de estimar su rendimiento ”corregido por optimismo” y evaluar la estabilidad del proceso de modelado (Iwagami and Matsui, 2022). Estas técnicas son esenciales, especialmente cuando no se dispone de un conjunto de datos externo independiente para la validación. Su objetivo es simular la aplicación del modelo a nuevos datos, cuantificando cuánto podría disminuir el rendimiento aparente.

Validación Cruzada (Cross-Validation, CV) La validación cruzada es una técnica de remuestreo que consiste en dividir repetidamente la muestra de desarrollo en subconjuntos de entrenamiento y un subconjunto de prueba (o validación). El modelo se ajusta en

el subconjunto de entrenamiento y luego se evalúa en el subconjunto de prueba, que actúa como datos ”no vistos”. Este proceso se repite múltiples veces con diferentes divisiones, y los resultados de rendimiento se promedian.

- **Proceso de k-fold Cross-Validation:**
  Es el método de validación cruzada más común. El procedimiento es el siguiente :

  1. La muestra de datos original se divide aleatoriamente en k subconjuntos (o ”folds”) de tamaño aproximadamente igual. Un valor común para k es 10.
  2. El proceso se itera k veces. En cada iteración i (desde 1 hasta k):
     - El fold i se reserva y se utiliza como conjunto de prueba.
     - Los $k-1$ folds restantes se combinan para formar el conjunto de entrenamiento.
     - El modelo pronóstico se desarrolla (entrena) utilizando únicamente los datos del conjunto de entrenamiento de esa iteración.
     - El modelo entrenado se aplica al conjunto de prueba (el fold i reservado) para obtener predicciones, y se calculan las métricas de rendimiento deseadas (por ejemplo, AUC, Brier Score, estadísticas de calibración).
  3. Las k estimaciones de las métricas de rendimiento obtenidas (una por cada fold utilizado como prueba) se promedian para obtener una estimación global del rendimiento del modelo. Esta media se considera una estimación más robusta del rendimiento esperado en datos nuevos que el rendimiento aparente.

- **Leave-One-Out Cross-Validation (LOOCV):**
  LOOCV es un caso extremo de k-fold CV donde el número de folds, k, es igual al número total de observaciones en la muestra, N.

  1. En cada una de las N iteraciones:
     - Una única observación se selecciona como conjunto de prueba.
     - Las $N1$ observaciones restantes se utilizan como conjunto de entrenamiento.
     - El modelo se entrena con las $N1$ observaciones y se evalúa en la observación única reservada.
  2. Las métricas de rendimiento de las N iteraciones se promedian. LOOCV tiene la ventaja de producir una estimación del error de prueba que es aproximadamente insesgada, ya que casi todos los datos se utilizan para entrenar en cada iteración. Sin embargo, puede tener una alta varianza en la estimación del error y ser computacionalmente muy intensivo para tamaños muestrales grandes.

  Por un lado, la validación cruzada hace un uso eficiente de los datos, ya que cada observación se utiliza tanto para el entrenamiento como para la prueba en alguna de las iteraciones. Generalmente proporciona una estimación más estable y menos sesgada del rendimiento en datos nuevos en comparación con una única división arbitraria de los datos en entrenamiento y prueba.
  Por otro lado, puede ser computacionalmente costosa, especialmente para modelos complejos o grandes conjuntos de datos (particularmente LOOCV). Si k es pequeño, la estimación del rendimiento puede tener una varianza considerable. Es importante

destacar que la validación cruzada, tal como se describe aquí, estima el rendimiento promedio esperado de un modelo desarrollado en una submuestra de tamaño aproximadamente $(k1)/kN$. No corrige directamente el optimismo del modelo final que se desarrolla utilizando toda la muestra original, sino que da una idea de la generalizabilidad del proceso de modelado.

- **Bootstrapping** El bootstrapping es una técnica de remuestreo versátil que implica la generación de múltiples "muestras bootstrap" a partir de la muestra de datos original. Cada muestra bootstrap se crea mediante muestreo aleatorio con reemplazo del conjunto de datos original y tiene el mismo tamaño (N) que la muestra original. Debido al muestreo con reemplazo, algunas observaciones originales pueden aparecer múltiples veces en una muestra bootstrap, mientras que otras pueden no aparecer en absoluto (en promedio, alrededor del 63.2 % de las observaciones originales únicas están presentes en cada muestra bootstrap).
  El bootstrapping es ampliamente utilizado para estimar la distribución muestral de un estadístico (como un coeficiente de regresión o una métrica de rendimiento como el AUC) y, a partir de ella, calcular intervalos de confianza. En el contexto de la validación de modelos, el bootstrapping es particularmente valioso para estimar y corregir el "optimismo" del modelo.
  El optimismo se define como la diferencia entre el rendimiento aparente de un modelo (evaluado en la misma muestra con la que se desarrolló) y el rendimiento que ese mismo modelo tendría en una nueva muestra de datos independiente. Los modelos tienden a ser optimistas (es decir, su rendimiento aparente es mejor que su rendimiento real en datos nuevos) debido al sobreajuste a la muestra de desarrollo.
  El procedimiento de bootstrapping para corregir el optimismo, popularizado por Harrell (2015) y otros, es el siguiente:

  1. **Desarrollo del Modelo Original y Rendimiento Aparente:** Entrenar el modelo pronóstico final (M_{orig}) utilizando la totalidad de la muestra de desarrollo original (D_{orig})
     Calcular la métrica de rendimiento de interés (por ejemplo, AUC) para M_{orig} evaluada en D_{orig}. Esto de denomina rendimiento aparente (por ejemplo. $AUC_{aparente}$).
  2. **Generación de Réplicas Bootstrap (Iterar B veces, por ejemplo, $B =$ 200 a 1000):** Para cada réplica bootstrap $b = 1, \ldots, B$:
     - **Crear Muestra Bootstrap:** Generar una muestra bootstrap ($D_b^\star$) tomando N observaciones de D_{orig} mediante muestreo aleatorio con reemplazo.
     - **Desarrollar Modelo Bootstrap:** Entrenar un nuevo modelo ($M_b^\star$) utilizando exactamente el mismo procedimiento de modelado que se usó para M_{orig} (incluyendo cualquier paso de selección de variables, transformación de predictores, etc.), pero esta vez utilizando la muestra bootstrap $D_b^\star$ como datos de entrenamiento
     - **Rendimiento del Modelo Bootstrap en la Muestra Bootstrap:** Evaluar el modelo $M_b^\star$ en su propia muestra de entrenamiento $D_b^\star$ para obtener su rendimiento (por ejemplo, $AUC_{boot,b}$).
     - **Rendimiento del Modelo Bootstrap en la Muestra Original:** Aplicar el modelo $M_b^\star$ (entrenado en $D_b^\star$) a la muestra original completa D_{orig} para obtener predicciones y calcular su rendimiento (por ejemplo, $AUC_{orig,b}$).

3. **Calcular el Optimismo para Cada Réplica:** La estimación del optimismo para la réplica b es la diferencia entre el rendimiento del modelo bootstrap en su propia muestra y su rendimiento en la muestra original: $O_b = AUC_{boot,b} - AUC_{orig,b}$. Esta diferencia refleja cuánto "mejor" rinde el modelo en los datos con los que fue ajustado en comparación con datos "nuevos" (la muestra original actúa como datos nuevos para $M_b^\star$).
4. **Calcular el Optimismo Promedio:** El optimismo promedio ($O_{promedio}$) se calcula como la media de los optimismos individuales de las B réplicas: $O_{promedio} = \frac{1}{B}\sum_{b=1}^{B} O_b$
5. **Calcular el Rendimiento Corregido por Optimismo:** La estimación del rendimiento del modelo original corregida por optimismo se obtiene restando el optimismo promedio del rendimiento aparente: $AUC_{corregido} = AUC_{aparente} - O_{promedio}$. Este $AUC_{corregido}$ es una estimación más realista del rendimiento que se esperaría de M_{orig} si se aplicara a una nueva muestra de la misma población.

Es fundamental que el desarrollo del modelo bootstrap replique fielmente todos los pasos involucrados en el desarrollo del modelo original, incluyendo cualquier forma de selección de variables, codificación de predictores, o ajuste de hiperparámetros. Si estos pasos no se incluyen en el bucle de bootstrapping, la estimación del optimismo será subestimada y, por lo tanto, el rendimiento corregido seguirá siendo demasiado optimista.
Tanto la validación cruzada como el bootstrapping para la corrección del optimismo son técnicas de remuestreo valiosas, pero abordan la evaluación del rendimiento desde ángulos ligeramente diferentes. La validación cruzada proporciona una estimación del rendimiento promedio de un modelo construido sobre una fracción de los datos disponibles (por ejemplo, $(k-1)/k$ de la muestra). En cambio, el procedimiento de bootstrapping para la corrección del optimismo se enfoca en estimar el rendimiento del modelo final, aquel que se construye utilizando toda la muestra de desarrollo. Esta última aproximación es particularmente útil porque el objetivo suele ser desplegar el modelo entrenado con todos los datos disponibles, y se desea una estimación de qué tan bien funcionará ese modelo específico. Frank Harrell es un defensor del uso del bootstrapping para la validación interna precisamente porque permite utilizar toda la muestra para el desarrollo del modelo final mientras se estima su probable rendimiento futuro sin necesidad de retener una porción de los datos como conjunto de prueba independiente (Harrell, 2015)

La siguiente tabla compara las principales estrategias de validación interna:

2.2. Validación Externa

Si bien la validación interna proporciona estimaciones valiosas del rendimiento esperado de un modelo, la validación externa se considera la prueba más rigurosa y definitiva de su capacidad de generalización.
La validación externa consiste en evaluar el rendimiento del modelo pronóstico final, tal como fue desarrollado y fijado en la cohorte de entrenamiento, utilizando un conjunto de datos completamente nuevo e independiente. Este conjunto de datos de validación externa no debe haber participado de ninguna manera en el desarrollo del modelo (ni en la selección de variables, ni en la estimación de coeficientes, ni en la elección de puntos de corte, etc.).

Cuadro 2.2: Comparación de Estrategias de Validación Interna y Estimación del Rendimiento.

Estrategia	**Principio Básico**	**Estimación Primaria**	**Ventaja Principal**	**Consideración Principal**
k-fold Cross-Validation	Dividir datos en k folds; entrenar en $k-1$, probar en 1; repetir k veces.	Rendimiento promedio de modelos entrenados en $(k-1)/k$ de los datos.	Uso eficiente de los datos; estimación más estable que una división simple.	No corrige directamente el optimismo del modelo final (entrenado en todos los datos); puede ser costoso computacionalmente.
Leave-One-Out CV (LOOCV)	Caso especial de k-fold CV con $k = n$; entrenar en $N-1$, probar en 1; repetir N veces.	Estimación casi insesgada del error de prueba.	Maximiza el tamaño del conjunto de entrenamiento en cada iteración.	Muy intensivo (para el ordenador) para N grandes; puede tener alta varianza en la estimación del error.
Bootstrap (con corrección de optimismo)	Remuestrear con reemplazo; estimar diferencia entre rendimiento en muestra bootstrap y muestra original.	Rendimiento del modelo final (entrenado en todos los datos) corregido por la sobreestimación debida al sobreajuste.	Proporciona una estimación del rendimiento del modelo específico que se pretende usar; utiliza todos los datos para el modelo final.	Requiere que todo el proceso de modelado se repita en cada muestra bootstrap; puede ser computacionalmente intensivo.

El propósito fundamental de la validación externa es determinar si las predicciones del modelo son precisas y fiables cuando se aplican a individuos que son genuinamente ”nuevos” para el modelo, reflejando así cómo se comportaría el modelo en un entorno de aplicación real. Un buen rendimiento en una cohorte externa robusta aumenta significativamente la confianza en la utilidad y generalizabilidad del modelo.

Requisitos Críticos para la Cohorte de Validación Externa La credibilidad de la validación externa depende críticamente de la independencia y las características de la cohorte de validación (Moons et al., 2012):

- **Independencia Total:** La cohorte de validación debe ser completamente distinta de la cohorte de desarrollo. Idealmente, esta independencia se logra de varias maneras:
    - **Validación Temporal:** Los datos de validación se recolectan en un período de tiempo posterior al de la cohorte de desarrollo. Esto prueba la estabilidad

del modelo a lo largo del tiempo.

- **Validación Geográfica/Multicéntrica:** Los datos de validación provienen de diferentes localizaciones geográficas, hospitales o centros de atención en comparación con la cohorte de desarrollo. Esto prueba la generalizabilidad del modelo a través de diferentes entornos de práctica.
- **Poblaciones con Características Diferentes (pero dentro del alcance previsto):** La cohorte de validación puede tener algunas diferencias en la distribución de características de los pacientes (por ejemplo, edad, comorbilidades) en comparación con la cohorte de desarrollo, siempre que siga representando la población objetivo para la cual se diseñó el modelo.

- **Consistencia en la Definición y Recolección de Datos:** Es crucial que las variables predictoras y la variable de resultado se definan y midan de la misma manera en ambas cohortes (desarrollo y validación externa). Las discrepancias en las definiciones o en los métodos de recolección pueden artefactualmente disminuir el rendimiento del modelo en la validación externa.

Proceso de Validación Externa El proceso implica los siguientes pasos:

1. **Aplicar el Modelo Original:** El modelo pronóstico original, con sus coeficientes y estructura exactamente como se estimaron en la cohorte de desarrollo, se aplica a cada individuo en la cohorte de validación externa para generar una probabilidad de evento predicha. No se realiza ningún reajuste o recalibración del modelo en esta etapa (a menos que el objetivo sea específicamente evaluar el impacto de la recalibración).

2. **Evaluar el Rendimiento:** Se calculan las mismas medidas de rendimiento (discriminación como AUC; calibración mediante el test de H-L y gráficos de calibración; Brier Score; Análisis de Curvas de Decisión, etc.) en la cohorte de validación externa, comparando las probabilidades predichas con los resultados observados en esta nueva cohorte.

Interpretación de los Resultados y Cuantificación de la Pérdida de Rendimiento

- **Comparación de Rendimiento:** El rendimiento del modelo en la cohorte externa se compara con el rendimiento obtenido en la cohorte de desarrollo (idealmente, el rendimiento corregido por optimismo de la validación interna).

- **Pérdida de Rendimiento (Performance Drop-off):** Es común y esperado observar una cierta disminución en el rendimiento cuando un modelo se aplica a datos externos. La magnitud de esta disminución es informativa: una pequeña caída sugiere buena generalizabilidad, mientras que una caída sustancial puede indicar sobreajuste al conjunto de desarrollo o que el modelo no es robusto a variaciones poblacionales o contextuales.

- **Umbrales de Aceptabilidad:** No existen umbrales universalmente aceptados para definir una ”pérdida de rendimiento aceptable”. Algunos estudios pueden predefinir criterios; por ejemplo, considera un modelo fiable si la pérdida en el AUC es inferior al 10 %. La interpretación a menudo depende del contexto clínico y de las consecuencias de una predicción errónea.

- **Implicaciones:** Si el rendimiento en la validación externa se mantiene en un nivel aceptable, aumenta considerablemente la confianza en la utilidad clínica del modelo. Si el rendimiento decae significativamente, el modelo puede requerir recalibración (ajuste del intercepto o de la pendiente de calibración para la nueva población) o incluso una reestimación completa. En algunos casos, se puede concluir que el modelo original no es generalizable a la población externa evaluada.

La validación externa no debe verse solo como una "prueba de aprobado/suspenso". Es una oportunidad crucial para aprender sobre los límites de aplicabilidad del modelo y sobre cómo las diferencias entre poblaciones, entornos de atención o incluso cambios a lo largo del tiempo pueden afectar su rendimiento. Si un modelo muestra un rendimiento deficiente en la validación externa, es importante investigar las posibles razones: ¿Ha cambiado la población de pacientes? ¿Existen diferencias en las prácticas de diagnóstico o tratamiento entre los centros? ¿Hay variabilidad en cómo se midieron los predictores? Las respuestas a estas preguntas pueden llevar a refinar el modelo, a definir más claramente su ámbito de aplicación, o a desarrollar estrategias para su actualización o adaptación.

Es fundamental distinguir claramente entre validación interna y externa. La validación interna evalúa la robustez del proceso de modelado y el grado de optimismo del modelo dentro de la población de la cual se extrajo la muestra de desarrollo. Proporciona una estimación de cuán bien se espera que el modelo funcione en individuos "similares" a los de la muestra de desarrollo. En contraste, la validación externa evalúa el rendimiento del modelo final y fijo en poblaciones y contextos potencialmente diferentes, ofreciendo la evidencia más sólida de su generalizabilidad y preparación para una implementación más amplia. Los modelos que carecen de una validación externa rigurosa suelen tener una relevancia clínica limitada y deben utilizarse con cautela.

2.3. Transparencia en la publicación de resultados: Adhesión a Directrices como TRIPOD

La calidad y utilidad de un estudio de desarrollo y validación de un modelo pronóstico dependen no solo de la robustez metodológica empleada, sino también de la transparencia y exhaustividad con la que se reportan sus métodos y resultados. Para este fin, se han desarrollado directrices de reporte estandarizadas (Collins et al., 2015).

- **Importancia de las Directrices de Reporte:** Seguir guías como TRIPOD (Transparent Reporting of a multivariable prediction model for Individual Prognosis Or Diagnosis) es fundamental para asegurar la reproducibilidad, permitir una evaluación crítica por parte de la comunidad científica, y facilitar la comparación y síntesis de diferentes modelos pronósticos.

- **Contenido Clave de TRIPOD:** La declaración TRIPOD proporciona una lista de verificación de ítems esenciales que deben ser reportados en cualquier publicación sobre un modelo de predicción. Estos ítems cubren todos los aspectos del estudio, incluyendo:

    - La fuente de los datos y las características de los participantes.
    - Los métodos de manejo de datos faltantes.

- La especificación completa del modelo (variables incluidas, su codificación, y cómo se manejaron las relaciones no lineales).
- Los métodos detallados utilizados para el desarrollo del modelo.
- Los métodos y resultados completos de la validación interna y externa, incluyendo las métricas de rendimiento (discriminación, calibración) con sus medidas de incertidumbre (por ejemplo, intervalos de confianza).

- **Beneficios Adicionales:** El cumplimiento de directrices como TRIPOD no solo mejora la calidad del reporte de un estudio individual, sino que también es crucial para la realización de revisiones sistemáticas y meta-análisis de modelos pronósticos. Al estandarizar la información que se reporta, estas guías permiten una evaluación más fiable de la evidencia disponible sobre modelos para una condición particular, ayudando a identificar los modelos más prometedores y las áreas donde se necesita más investigación. Esto, a su vez, impulsa el progreso en el campo del modelado pronóstico. El Análisis de Curvas de Decisión (DCA), por ejemplo, se ha incorporado como un elemento a considerar en la declaración TRIPOD, reconociendo su importancia para evaluar la utilidad clínica.

Capítulo 3

Scores pronóstico

Una vez se ha obtenido y validado el mejor modelo pronóstico multivariable, el siguiente paso consiste en su transformación en un índice o score clínico. Este proceso es fundamental para que el modelo sea útil en la práctica diaria.

La creación del score consiste en transformar los coeficientes de regresión (β) del modelo final en una serie de valores simples, generalmente números enteros. A cada predictor del modelo se le asigna una puntuación específica basada en la magnitud de su coeficiente. De esta forma, para obtener el riesgo de un paciente, el clínico solo necesita sumar los puntos correspondientes a las características presentes en ese individuo.

A partir del valor total de esa suma, se establecen puntos de corte para considerar diferentes grupos de riesgo (por ejemplo, riesgo bajo, intermedio y alto), lo que permite una toma de decisiones clínicas rápida, estandarizada y objetiva.

1 Elaboración de Índices Pronóstico (Scores) a partir de Coeficientes Logísticos

Esta sección aborda el proceso de transformación de los coeficientes de un modelo de regresión logística en un índice pronóstico o score clínico, una herramienta diseñada para ser simple, manejable y útil en la práctica clínica diaria. Se detallará el método clásico, tomando como referencia conceptual el enfoque utilizado en estudios como el de Nguyen y Graviss Nguyen and Graviss (2018)

1.1. Principios Metodológicos

El objetivo fundamental al crear un score pronóstico a partir de un modelo de regresión logística es convertir los coeficientes β, que se encuentran en la escala de log-odds y pueden ser difíciles de interpretar directamente por los clínicos, en un sistema de puntos simple, aditivo y clínicamente relevante. Este sistema de puntos debe permitir al profesional de la salud calcular rápidamente una puntuación total para un paciente, la cual se correlaciona con la probabilidad del evento pronóstico de interés.

Para iniciar este proceso, es crucial haber desarrollado un modelo de regresión logística multivariable robusto y bien validado. De este modelo, se seleccionan las variables predictoras que han demostrado ser factores de riesgo (o protectores) verdaderos e independientes para el resultado. Generalmente, estas son las variables que alcanzan significancia estadística en el modelo multivariable (por ejemplo, con un valor $p < 0.05$), aunque otros

criterios basados en la relevancia clínica o métodos de selección de variables más sofisticados también pueden aplicarse.

La transformación de coeficientes continuos β en puntos enteros implica inherentemente una simplificación y, por ende, una cierta pérdida de información o precisión en comparación con el uso de la ecuación logística completa (Steyerberg, 2019). Sin embargo, esta pérdida se considera aceptable si la ganancia en simplicidad, interpretabilidad y usabilidad clínica es sustancial. La creación de un score es, en muchos sentidos, un ejercicio de equilibrio. Se persigue la máxima simplicidad para facilitar su uso en entornos clínicos a menudo con limitaciones de tiempo (números enteros, fáciles de sumar mentalmente o con una calculadora simple), minimizando al mismo tiempo la pérdida de la capacidad predictiva original del modelo estadístico. Alcanzar este equilibrio óptimo no siempre es sencillo y a menudo requiere un juicio experto y una evaluación cuidadosa del impacto de la simplificación en el rendimiento del score. Un score demasiado simplificado (con muy pocos puntos o categorías de variables muy amplias) podría perder poder discriminatorio. Por el contrario, un score con una granularidad excesiva (muchos puntos posibles, rangos muy estrechos para variables continuas) podría perder su principal ventaja –la simplicidad– sobre el uso directo de la ecuación logística. El hecho de que estudios como el de Nguyen y Graviss Nguyen and Graviss (2018) logren desarrollar un score ”simple” que, no obstante, mantiene una ”buena discriminación” (AUC = 0.82) , sugiere que es posible alcanzar este delicado equilibrio.

1.2. Descripción del Método Clásico de Asignación de Puntos

El método clásico para convertir los coeficientes β de un modelo de regresión logística en un sistema de puntos aditivos implica varios pasos sistemáticos. Aunque los detalles específicos pueden variar ligeramente entre diferentes scores, los principios generales son consistentes.

- **Paso 1: Establecimiento de un Punto de Referencia o Unidad de Puntuación.**
  Una vez obtenidos los coeficientes β, se necesita establecer una ”unidad” o ”escala” para los puntos. Hay varias formas de hacerlo:

  1. **Usar el coeficiente más pequeño:** Se identifica la variable predictora (o categoría de variable) con el coeficiente β más pequeño en valor absoluto (pero significativo) entre todas las incluidas en el score. Este β_{minimo}(o una fracción de él, como $\frac{\beta_{minimo}}{2}$) puede servir como el divisor o la ”unidad de puntos de referencia” ($\beta_{referencia}$). Cada punto en el score correspondería aproximadamente a este incremento en el log-odds.
  2. **Elegir una constante de escalado (B):** Se selecciona una constante B (por ejemplo, 10). Los puntos para cada predictor se obtienen multiplicando su coeficiente β por esta constante B.
  3. **Asignar un número de puntos al predictor más influyente:** Se puede decidir que el predictor con el mayor coeficiente β (en valor absoluto) reciba un número determinado de puntos (por ejemplo, 10 o 100 puntos), y luego escalar los puntos de los demás predictores proporcionalmente.

La elección del $\beta_{referencia}$ o la constante B es fundamental, ya que determinará la escala general y el rango de los puntos del score. Una elección inadecuada puede llevar a un score con puntos que son números excesivamente grandes o, por el contrario, fracciones muy pequeñas que luego son difíciles de redondear a enteros significativos, afectando la usabilidad y la interpretabilidad del score. El objetivo es que la escala de puntos sea intuitiva y refleje adecuadamente las diferencias relativas en la magnitud de los efectos de los predictores (sus coeficientes β).

- **Paso 2: Asignación de Puntos Base.**
  Para cada variable categórica, la categoría de referencia (aquella contra la cual se comparan las demás y que conceptualmente tiene un $\beta = 0$ para esa comparación) recibe 0 puntos. Para las variables continuas que se incluyen como tales (sin categorizar), se debe definir un valor o rango de referencia que corresponda a 0 puntos. Si una variable continua se categoriza para el score (como es común en scores como el de Framingham), cada categoría tendrá su propia asignación de puntos, siendo la categoría de referencia la que recibe 0 puntos.

- **Paso 3: Cálculo de Puntos para Cada Variable/Categoría.**
  Para cada predictor X_j (o cada categoría de un predictor categórico que no sea la de referencia) con su respectivo coeficiente β_j del modelo final, los puntos asignados (P_j) se calculan dividiendo su coeficiente por el $\beta_{referencia}$ (si se usó ese método) o multiplicándolo por la constante de escalado B:

$$P_j = \frac{\beta_j}{\beta_{referencia}} \ , \ o \ P_j = \beta_j B$$

  Si se utilizan odds ratios (OR) directamente, aunque es menos común para la creación de scores sumativos, una aproximación sería transformar primero los OR a la escala logarítmica (ya que $\ln(OR_j) = \beta_j$) y luego proceder como se indicó con los β. El artículo de SciELO menciona la transformación de coeficientes β en odds ratios y luego el redondeo de estos valores para conformar el score, aunque el método más directo y matemáticamente consistente para scores aditivos es trabajar con los β o sus log-odds.

  Es importante manejar adecuadamente los coeficientes negativos, que corresponden a factores protectores. Si se sigue la fórmula anterior, un β_j negativo resultará en puntos negativos. En algunos scores, esto se acepta (y los puntos negativos se restan del total). En otros, se prefiere que todos los puntos sean positivos y que una puntuación más alta siempre indique mayor riesgo. Esto puede lograrse redefiniendo las categorías de referencia (eligiendo la categoría de ”menor riesgo” como referencia con 0 puntos) o ajustando la escala. Por ejemplo, en el estudio de Nguyen y Graviss Nguyen and Graviss (2018), la variable ”edad $\geq$ 45 años” tuvo un OR crudo de 2.78 en el análisis univariado , lo que sugiere que en el modelo multivariable final (cuyos coeficientes no se detallan en los fragmentos) contribuiría con puntos positivos al score de mortalidad.

- **Paso 4: Redondeo de Valores para Obtener Números Enteros.**
  Los puntos calculados en el paso anterior (P_j) raramente serán números enteros. Para facilitar la suma manual y la aplicación rápida por parte del clínico, estos valores se redondean al número entero más cercano. Este redondeo introduce una pequeña

aproximación y, por tanto, una ligera pérdida de precisión en comparación con el modelo logístico original. Sin embargo, esta se considera generalmente aceptable si el score resultante sigue teniendo un buen rendimiento predictivo y la ganancia en simplicidad es considerable.

- **Paso 5: Suma Total de Puntos y Estratificación del Riesgo.** El score total para un paciente individual se obtiene sumando los puntos asignados a cada una de sus características (variables predictoras) según su estado o valor.

$$Score_{Total} = \sum_j P_j.$$

Una vez calculado el puntaje total, el siguiente paso es utilizarlo para clasificar a los pacientes en grupos de riesgo (por ejemplo, riesgo bajo, medio y alto). Esta estratificación es el objetivo final para facilitar la toma de decisiones clínicas. La elección de los puntos de corte para definir estos grupos es una decisión crucial y puede basarse en diferentes aproximaciones:

- **Criterio Clínico:** Los puntos de corte se establecen basándose en el conocimiento médico existente, guías de práctica clínica o el consenso de un panel de expertos. Este método asegura que las categorías de riesgo tengan una relevancia y una interpretación directa en el contexto clínico.
- **División por Cuantiles:** Es un enfoque estadístico donde la distribución del score en la población de estudio se divide en grupos de igual tamaño. Los más comunes son los terciles (tres grupos), cuartiles (cuatro grupos) o quintiles (cinco grupos). La ventaja es su simplicidad, aunque los umbrales generados pueden no corresponder necesariamente a cambios clínicamente significativos en el riesgo.
- **Análisis de la Estructura de los Datos (Puntos de Corte Óptimos):** Este método busca identificar umbrales de manera empírica, analizando la relación entre el score y el riesgo del evento. El objetivo es encontrar los ”puntos de corte óptimos” que mejor separen a los pacientes según su desenlace. Para ello se pueden usar técnicas estadísticas, como el análisis de la curva ROC (buscando el punto que maximiza el índice de Youden) o algoritmos de particionamiento recursivo (árboles de decisión).

Independientemente del método, el objetivo es crear categorías que sean clínicamente relevantes y que muestren diferencias claras en el riesgo del evento. Por ejemplo, en su estudio, Nguyen and Graviss (2018) categorizaron su score de mortalidad en tres grupos: riesgo bajo (<20 puntos), riesgo medio (20-25 puntos) y riesgo alto (>25 puntos), observando tasas de mortalidad marcadamente diferentes en cada grupo (2.6 %, 11.9 % y 44.4 %, respectivamente), lo que demuestra una estratificación exitosa. A continuación, se presenta una tabla hipotética para ilustrar el proceso de asignación de puntos, similar al estilo que podría seguirse en un estudio como el de Nguyen y Graviss o el Framingham Risk Score. Esta tabla es crucial porque materializa el proceso abstracto de conversión de coeficientes en puntos. Permite al lector visualizar, paso a paso, cómo se podría derivar la puntuación para cada factor de riesgo, cumpliendo directamente con la solicitud del usuario de explicar ”cómo se transforman los coeficientes... en una puntuación simple”. Ilustra el método clásico y el necesario redondeo para la facilidad de uso.

Cuadro 3.1: Ejemplo de Tabla de Puntuación

Variable Predictora	**Categoría o Valor**	**Coef.** β	**Puntos Intermedios (ej:** $\beta/0.25$**,** $\beta_{\mathbf{ref}} = 0.25$**)**	**Puntos Asignados**
Edad	$\geq$ 65 años	0.70	$0.70/0.25 = 2.80$	3
	$<$ 65 años (Ref.)	0	0	0
Comorbilidad Severa	Presente	1.05	$1.05/0.25 = 4.20$	4
	Ausente (Ref.)	0	0	0
Marcador Biol. Elevado	Sí	0.55	$0.55/0.25 = 2.20$	2
	No (Ref.)	0	0	0
Factor Protector	Presente	-0.40	$-0.40/0.25 = -1.60$	-2*
	Ausente (Ref.)	0	0	0

**Nota sobre Factor Protector: Si se desea evitar puntos negativos, se podría asignar 0 puntos a "Presente" y 2 puntos a "Ausente", redefiniendo la referencia, o ajustar la constante de escalado y el intercepto del score para que todos los puntos sean no negativos.*

1.3. Ejemplo Práctico

Para ilustrar de manera más concreta, supongamos que hemos desarrollado un modelo de regresión logística para predecir un evento adverso y hemos obtenido los siguientes coeficientes β significativos para tres variables (simplificado):

- **Variable** A **(Categórica: Presente vs. Ausente, Ausente=referencia):** $\beta_A = 0.80$
- **Variable** B **(Categórica: Nivel Alto vs. Nivel Bajo, Nivel Bajo=referencia):** $\beta_B = 1.25$
- **Variable** C **(Factor Protector, Categórica: Sí vs. No, No=referencia):** $\beta_C = -0.50$

Creación del score

1. **Coeficientes del modelo final:** Ya los tenemos; $\beta_A = 0.80$, $\beta_B = 1.25$ y $\beta_C = -0.50$
2. **Establecimiento de un punto de referencia:** Podríamos elegir una constante de escalado, por ejemplo, $B = 2$. O bien, podríamos buscar el β más pequeño en valor absoluto (que es 0.50 para β_C), o una fracción y usarlo como $\beta_{referencia}$. Para este ejemplo, usemos $\beta_{referencia} = 0.50/2 = 0.25$.

3. **Asignación de puntos base:** Las categorías de referencia (Ausente para A, Nivel Bajo para B, No para C) reciben 0 puntos.

4. **Cálculo de puntos para cada variable/categoría**:
   $P_A = 0.80/0.25 = 3.2$ para Variable A Presente.
   $P_B = 1.25/0.25 = 5.0$ para Variable B en Nivel Alto.
   $P_C = -0.50/0.25 = -2.0$ para Variable C Presente.

5. **Redondeo de valores:**
   $P_A \approx 3$ *puntos.*
   $P_B = 5$ *puntos.*
   $P_C = -2$ *puntos.*

6. **Suma total de puntos y estratificación:** Un paciente con la Variable A presente (3 puntos), Variable B en Nivel Alto (5 puntos) y Variable C ausente (0 puntos) tendría un score total de 3+5+0=8 puntos. Otro paciente con A ausente (0), B en Nivel Bajo (0) y C presente (-2 puntos) tendría un score de $0 + 0 - 2 = -2$ puntos. Luego se definirían umbrales para estratificar el riesgo (por ejemplo, <0 bajo, 0-4 medio, >4 alto).

El estudio de Nguyen y Graviss Nguyen and Graviss (2018) aplicó estos principios para derivar su score de mortalidad a partir de seis variables predictoras: edad, residencia en un centro de atención a largo plazo, presencia de tuberculosis meníngea, hallazgos en la radiografía de tórax, cultivo de esputo positivo para TB, y la no conversión del cultivo de esputo o resultado desconocido. Aunque los coeficientes β exactos y el método de escalado específico no se proporcionan en los fragmentos disponibles, el resultado fue un score simple y validado que categorizaba a los pacientes en grupos de bajo, medio y alto riesgo de mortalidad. Esta falta de detalle en la publicación sobre la derivación exacta de los puntos a partir de los coeficientes β es una limitación común en algunos estudios. Idealmente, para la transparencia y la reproducibilidad, se debería describir con precisión cómo se realizó la conversión de los coeficientes del modelo logístico a los puntos del score, tal como se aboga en las guías de reporte de modelos de predicción. Una descripción completa permitiría a otros investigadores comprender a fondo las propiedades del score y, potencialmente, replicar o adaptar la metodología.

2 Herramientas de Software (R) Recomendadas

La implementación de la metodología descrita en este trabajo se puede llevar a cabo de forma eficiente y reproducible utilizando el software estadístico R, gracias a su ecosistema de paquetes especializados. Algunas de las herramientas más relevantes para cada etapa del proceso de construcción de un índice pronóstico son:

- **Selección de Variables:** Para los métodos clásicos de búsqueda por pasos (stepwise), la función `step()` del paquete base `stats` es la herramienta estándar, utilizando el AIC como criterio. Para los métodos de regularización, el paquete `glmnet` es la implementación de referencia para ajustar modelos LASSO, Ridge y Elastic Net, e incluye la función `cv.glmnet()` para la selección del parámetro de penalización óptimo mediante validación cruzada.

- **Categorización de Variables:** Para la segmentación supervisada de variables, paquetes como `smbinning` y `woeBinning` son muy útiles, ya que automatizan la búsqueda de los mejores puntos de corte y calculan métricas como el Weight of Evidence (WOE) y el Information Value (IV).
- **Validación del Modelo:** El rendimiento del modelo se puede evaluar de forma exhaustiva con paquetes específicos. `pROC` es el más popular para el análisis de la capacidad de discriminación (curvas ROC y AUC). Para la calibración y la validación interna mediante bootstrap para corregir el optimismo, el paquete `rms` es especialmente potente, con funciones como `validate()` y `calibrate()`.
- **Creación del Score:** La etapa final de conversión de los coeficientes del modelo en un sistema de puntos aditivo no depende de un único paquete. Generalmente, este es un proceso manual que se realiza utilizando funciones base de R para extraer los coeficientes (`coef()`) y aplicar las operaciones de escalado y redondeo necesarias para construir la tabla de puntuación final.

Capítulo 4

Aplicación Práctica

1 Descripción de los datos

El presente estudio se basa en el conjunto de datos de acceso público ”Heart Failure Prediction from Clinical and Laboratory Data in Zigong”, alojado en la plataforma Physionet (Gu et al., 2022). Se trata de un estudio de cohorte retrospectivo que incluye a 2,008 pacientes ingresados por insuficiencia cardíaca en el Zigong Fourth People's Hospital (Sichuan, China) entre diciembre de 2016 y junio de 2019. La base de datos original consta de 168 variables que abarcan un amplio espectro de información, incluyendo características demográficas, datos clínicos basales al ingreso, hallazgos de laboratorio, comorbilidades, hallazgos ecocardiográficos y datos de seguimiento.

El objetivo de este capítulo práctico es desarrollar y validar un modelo pronóstico de regresión logística para predecir el riesgo de muerte por insuficiencia cardíaca en un tiempo de 6 meses.

2 Metodología

2.1. Limpieza de Datos

Riesgo de Fuga de Datos Antes de construir cualquier modelo predictivo, un paso fundamental es prevenir un error metodológico conocido como fuga de datos o data leakage. Este problema ocurre cuando, durante su entrenamiento, el modelo tiene acceso a información que en la vida real no estaría disponible en el momento de hacer una predicción.

Para entenderlo mejor, imaginemos nuestro objetivo: predecir si un paciente con insuficiencia cardíaca fallecerá basándonos únicamente en los datos disponibles el día de su diagnóstico. Una fuga de datos ocurriría si, por error, incluyéramos como variable predictora algo como ”el paciente recibió un trasplante de corazón”. Esta información solo se conoce después del diagnóstico inicial y está directamente relacionada con la evolución del paciente. El modelo aprendería una ”pista del futuro” que no tendrá disponible para nuevos pacientes en el momento de la predicción, llevando a que el modelo parezca extremadamente preciso en las pruebas, pero sea inútil en la práctica clínica.

Para garantizar la integridad de nuestro estudio y evitar este grave error, se aplicó una regla estricta: solo se utilizaron variables cuya información estuviera disponible en el momento del diagnóstico inicial. Esto implicó la exclusión sistemática de cualquier

dato que reflejara eventos o mediciones posteriores a ese momento. Concretamente, se eliminaron del análisis las siguientes variables:

- **Resultados alternativos y eventos de seguimiento:** Variables como `outcome.during.hospitalization`, `death.within.28.days`, `re.admission.within.3.months`, etc
- **Información sobre la estancia hospitalaria:** Variables como `dischargeDay` o `time.of.death..days.from.admission.`

Eliminación de Variables Redundantes y No Pronósticas Además de las variables que suponen un riesgo de fuga de datos, se procedió a la eliminación de otras categorías de variables para mejorar la robustez, interpretabilidad y generalizabilidad del modelo final.

- **Identificadores Únicos:** Se excluyeron las variables `X` e `inpatient.number`. Estas columnas actúan como meros índices de fila o identificadores de paciente, careciendo de cualquier valor intrínseco o biológico para la predicción del pronóstico.
- **Variables Redundantes:** Se eliminaron los componentes individuales de la Escala de Coma de Glasgow (GCS): `eye.opening`, `verbal.response` y `movement`. La información contenida en estas tres variables está completamente agregada en la puntuación total `GCS`. Mantenerlas en el modelo introduciría una multicolinealidad perfecta y añadiría una complejidad innecesaria sin aportar nueva información predictiva.
- **Variables Administrativas/Logísticas:** Se excluyeron variables como `admission.ward` (planta de ingreso), `occupation` (ocupación) y `discharge.department` (departamento de alta). Aunque estas variables podrían mostrar una correlación estadística con el resultado, su inclusión es problemática por varias razones. Frecuentemente, actúan como proxies o sustitutos de factores socioeconómicos, de gravedad clínica o de procesos hospitalarios no medidos. Por ejemplo, ser admitido directamente en una unidad de cardiología especializada podría correlacionarse con un mejor pronóstico, pero este efecto se debe probablemente a los protocolos de triaje o a la especialización del equipo, no a la planta de ingreso en sí misma. Incluir estas variables podría llevar a un modelo que aprenda los procesos internos de un hospital específico en lugar de la fisiopatología del paciente, lo que dañaría gravemente su interpretabilidad y su capacidad de ser generalizado a otros centros sanitarios. Al eliminar estas variables, se fuerza al modelo a basarse en predictores intrínsecos al estado del paciente (signos vitales, analíticas), promoviendo la construcción de un modelo más universal y biológicamente plausible.

Gestión de Datos Faltantes La presencia de valores ausentes (missing data) es una característica inherente y un desafío constante en los datos derivados de registros electrónicos de salud (EHR). Se implementó una estrategia de dos pasos para gestionar este problema.

1. **Exclusión de Variables con Alta Proporción de Ausentes.**
   En primer lugar, se identificaron y eliminaron todas aquellas variables que presentaban una cantidad muy elevada de valores ausentes (más de 1,000 registros faltantes sobre un total de 2,008). Esta lista incluía un panel completo de gases en sangre y

otras analíticas menos comunes. La justificación de esta medida radica en que intentar imputar una proporción tan masiva de datos (superior al 50 %) introduciría un ruido y un sesgo inaceptables en el análisis. La imputación masiva podría distorsionar la distribución original de la variable y debilitar la validez de los resultados, ya que las estimaciones se basarían en una fracción muy pequeña de los datos reales.

2. **Imputación Simple de Valores Restantes.**
   Para las variables restantes, que presentaban una proporción de datos faltantes mucho menor, se aplicó una estrategia de imputación simple. La elección del método de imputación se basó en la naturaleza de cada variable:

   - **Variables Numéricas** Se utilizó la imputación por la mediana. Se prefirió la mediana sobre la media debido a su robustez frente a valores atípicos (outliers) y distribuciones asimétricas, características muy comunes en los datos clínicos y de laboratorio. La media es muy sensible a valores extremos, que pueden desplazarla y hacerla un mal representante del centro de la distribución.
   - **Variables Categóricas:** Se empleó la imputación por la moda, es decir, reemplazando el valor ausente por la categoría más frecuente en la variable. Este es el análogo lógico de la mediana para datos no numéricos.

   Esta estrategia de imputación simple (mediana/moda) conlleva una asunción implícita sobre el mecanismo de la pérdida de datos: se asume que los datos son Missing Completely at Random (MCAR) o Missing at Random (MAR). Esto significa que la probabilidad de que un valor esté ausente no depende del propio valor que falta. Aunque es una simplificación —los datos podrían ser Missing Not at Random (MNAR), donde la propia ausencia de un dato es informativa—, este enfoque pragmático es estándar en la construcción de modelos predictivos, ya que prioriza la simplicidad y la viabilidad sobre métodos más complejos como la imputación múltiple, que requerirían supuestos adicionales sobre la naturaleza de la ausencia.

Tras completar todo el proceso de curación, limpieza e imputación, se obtuvo un conjunto de datos final con 2,008 observaciones y 116 variables predictoras candidatas, sin valores ausentes.

2.2. Selección de variables predictoras

Análisis Univariado Inicial Como paso exploratorio inicial, se evaluó la asociación de cada una de las 116 variables predictoras candidatas con la mortalidad a seis meses de forma individual. Para ello, se ajustó un modelo de regresión logística simple para cada predictor. Este análisis univariado permite obtener una primera impresión de la fuerza de la asociación no ajustada de cada variable con el resultado, cuantificada mediante el Odds Ratio (OR), su intervalo de confianza (IC) del 95 % y el valor p.

Los resultados de este cribado masivo (no mostrados en su totalidad por razones de brevedad, pero disponibles en el apéndice del trabajo) revelaron que un gran número de variables mostraban una asociación estadísticamente significativa con la mortalidad. Entre los predictores más potentes a nivel univariado se encontraron variables de laboratorio como los niveles de NT-proBNP, nitrógeno ureico en sangre (BUN) y creatinina, así como variables clínicas como la edad, la frecuencia respiratoria y la presión arterial sistólica. Este análisis, si bien es informativo, no es suficiente para la selección final de variables, ya

que no tiene en cuenta las interrelaciones y el posible solapamiento (colinealidad) entre los predictores. Sirve, no obstante, como una fase de exploración y confirmación de que las variables incluidas en el análisis tienen, en general, una relación plausible con el desenlace estudiado.

LASSO Para abordar estos desafíos de forma simultánea, se optó por utilizar la regresión LASSO (Least Absolute Shrinkage and Selection Operator). LASSO (Tibshirani, 1996) es una técnica de regularización que modifica la función de coste de la regresión logística tradicional añadiendo un término de penalización. Esta penalización es proporcional a la suma de los valores absolutos de los coeficientes del modelo (conocida como norma L1). El efecto de esta penalización es "encoger" los coeficientes de las variables hacia cero. Crucialmente, a diferencia de otras técnicas como la regresión Ridge Hoerl and Kennard (1970) (penalización L2), LASSO puede forzar que los coeficientes de las variables menos importantes sean exactamente cero, eliminándolas del modelo de manera efectiva. Esta propiedad convierte a LASSO en una herramienta ideal para la selección automática de características en contextos de alta dimensionalidad.

El grado de penalización es controlado por un hiperparámetro, lambda (λ). Un valor de $\lambda = 0$ equivale a una regresión logística estándar, mientras que un valor de λ muy elevado forzaría todos los coeficientes a ser cero. La elección del valor óptimo de λ es crítica. En este análisis, se determinó mediante un proceso de validación cruzada de 10-folds (10-fold cross-validation). El conjunto de datos se dividió en 10 subconjuntos; el modelo se entrenó repetidamente con 9 de ellos y se evaluó en el restante, rotando el subconjunto de evaluación. Se seleccionó el valor de λ que minimizaba el error de predicción promedio (en este caso, la devianza binomial) a lo largo de las 10 iteraciones.

Tras la aplicación de este procedimiento, LASSO seleccionó un subconjunto parsimonioso de variables predictoras, que se detallan en la siguiente tabla

Cuadro 4.1: Variables Seleccionadas por el Procedimiento de Regularización LASSO

Variables Predictoras		
Killip.gradeIII	Killip.gradeIV	congestive.heart.failure1
liver.disease1	type.II.respiratory.failureTypeII	consciousnessNonresponsive
fio2	acute.renal.failure1	creatinine.enzymatic.method
urea	cystatin	platelet
neutrophil.ratio	thrombin.time	glutamic.oxaloacetic.transaminase
creatine.kinase.isoenzyme	brain.natriuretic.peptide	white.globulin.ratio
globulin	GCS	

Nótese que variables como `Killip.grade` han sido categorizadas automáticamente y separadas en `Killip.gradeIII` y `Killip.gradeIV`, que han sido seleccionadas por LASSO.

2.3. Construcción del Modelo Logístico

Con el conjunto de 20 predictores seleccionados por LASSO, se procedió a construir el modelo pronóstico final. Para ello, se ajustó un modelo de regresión logística multivariada estándar, utilizando únicamente las variables de la Tabla 4.1 para predecir la mortalidad a 6 meses. Este modelo permite estimar el efecto ajustado y simultáneo de cada predictor

sobre el resultado, controlando por el efecto de las demás variables incluidas en el modelo. Una vez construido el modelo final, se procedió a una validación integral para cuantificar su rendimiento y fiabilidad. Para evaluar su capacidad de discriminación, se realizó un análisis de la curva ROC (AUC-ROC). La calibración del modelo, es decir, la concordancia entre el riesgo predicho y el observado, se evaluó mediante dos métodos complementarios: el test de Hosmer-Lemeshow y la construcción de un gráfico de calibración. Finalmente, para estimar la robustez y la estabilidad del modelo en datos no vistos, se aplicó una validación cruzada de 10 folds (10-fold cross-validation).

2.4. Construcción del Modelo pronóstico

Para construir el modelo pronóstico final en forma de una escala de puntos simple, el primer paso fue convertir los predictores continuos en variables categóricas. Se utilizó una doble estrategia para ello: la Escala de Coma de Glasgow (GCS) se categorizó según umbrales clínicos ya establecidos (Leve, Moderado y Grave) , mientras que el resto de variables continuas se agruparon utilizando sus cuartiles. Una vez con todas las variables en formato categórico, se procedió a la asignación de puntos. Para ello, se ajustó un nuevo modelo de regresión logística y se identificó el coeficiente con el valor absoluto más pequeño para usarlo como unidad base de escalado. Finalmente, todos los coeficientes del modelo se dividieron por esta unidad base y se redondearon al entero más cercano para obtener la puntuación final para cada característica. Este método asegura que el peso relativo de cada predictor en el modelo estadístico se preserve fielmente en la escala de puntos, manteniendo la integridad pronóstica del modelo original.

3 Resultados

3.1. Análisis univariado

Los predictores más potentes estuvieron directamente relacionados con la severidad del estado del paciente en el momento del ingreso.

- Un menor nivel de consciencia, medido por la Escala de Coma de Glasgow (GCS), se asoció de forma muy robusta con una mayor supervivencia. Por cada punto de incremento en el GCS (indicativo de una mejoría neurológica), las odds de muerte disminuyeron un 33 % (Odds Ratio [OR] = 0.67; Intervalo de Confianza [IC] 95 %: 0.61-0.73; $p < 0.001$).

- La presencia de shock cardiogénico, indicado por un Killip Grado IV, fue el predictor de riesgo individual más potente, incrementando las odds de muerte aproximadamente 47 veces en comparación con la categoría de referencia (OR = 47.5; IC 95 %: 16.6-172; p¡0.001).

- La necesidad de soporte respiratorio también fue un indicador clave. No requerir ningún tipo de soporte (`respiratory.support.None`) se identificó como un factor fuertemente protector, reduciendo las odds de muerte en un 94.6 % (OR = 0.05; IC 95 %: 0.02-0.14; $p < 0.001$).

El deterioro de la función renal emergió como un segundo dominio pronóstico de gran importancia, evidenciado por múltiples biomarcadores.

- Niveles elevados de urea sérica se asociaron significativamente con un mayor riesgo, donde cada aumento de 1 mmol/L incrementaba las odds de muerte en un 11 % (OR = 1.11; IC 95 %: 1.08-1.15; $p < 0.001$).

- De forma similar, la cistatina C, otro marcador sensible de función renal, mostró una fuerte asociación con la mortalidad (OR = 1.73; IC 95 %: 1.43-2.08; $p < 0.001$).

- Consistentemente, una mayor tasa de filtración glomerular (eGFR), indicativa de una mejor función renal, actuó como un factor protector (OR = 0.98; IC 95 %: 0.97-0.99; $p < 0.001$).

Otras alteraciones analíticas y enfermedades previas mostraron asociaciones significativas. La hiperpotasemia (niveles altos de potasio) se identificó como un factor de riesgo importante (OR = 1.80; IC 95 %: 1.35-2.39). Entre las comorbilidades, la presencia de enfermedad hepática (`liver.disease1`) se asoció con un riesgo casi cinco veces mayor de mortalidad (OR = 4.69; IC 95 %: 2.09-9.49).

Este análisis exploratorio sugiere que el perfil de mayor riesgo corresponde a un paciente que ingresa en un estado de alta gravedad (bajo GCS, alto grado Killip) y con evidencia de disfunción multiorgánica, destacando el compromiso renal. Estos hallazgos univariados, aunque informativos, no consideran la interdependencia entre predictores y sirvieron como base para la posterior selección de variables multivariable con el fin de construir un modelo ajustado.

3.2. Modelo Logístico

Una vez seleccionadas las variables por LASSO, incluso en el modelo ajustado, un núcleo de variables mantiene una fuerte asociación estadística con la mortalidad, sugiriendo que son factores pronósticos independientes y robustos.

- **Gravedad Clínica (`Killip.grade|`):** Sigue siendo uno de los predictores más potentes. En comparación con el Grado I, estar en Grado III (OR 4.9) o Grado IV (OR 7.5) incrementa masivamente las odds de muerte, incluso después de considerar todos los demás factores.

- **Comorbilidades:** La presencia de enfermedad hepática (`liver.disease1`) se mantiene como un factor de riesgo significativo ($OR \approx 3.0$, $p = 0.036$).

- **Marcadores de Laboratorio:** Varias pruebas de laboratorio demuestran ser predictores independientes:

  - Un tiempo de trombina (`thrombin.time`) más prolongado se asocia con un mayor riesgo de muerte ($OR \approx 1.03$ por unidad, $p = 0.004$).
  - Niveles más altos de BNP (`brain.natriuretic.peptide`) y GOT (`glutamic.oxaloacetic.transaminase`) también se asocian significativamente con una mayor mortalidad.

- **Hallazgo Contraintuitivo** (`congestive.heart.failure1`): e forma muy interesante, tener un diagnóstico previo de insuficiencia cardíaca congestiva aparece como un fuerte factor protector ($OR \approx 0.14$, $p < 0.001$). Esto no significa que tener la enfermedad sea bueno, sino que, probablemente, estos pacientes ya estaban bajo un manejo y tratamiento médico optimizado antes del ingreso, lo que les confiere una

ventaja pronóstica frente a pacientes que debutan con una insuficiencia cardíaca aguda.

Es igualmente importante notar qué variables, a pesar de ser muy potentes en el análisis univariado, pierden su significancia estadística ($p > 0.05$) en el modelo final.
`GCS`, `urea`, `cystatin`. `glomerular.filtration.rate` eran los predictores "estrella" en el análisis univariado, pero ahora no son significativos.
Esto no significa que no sean importantes. Significa que su efecto pronóstico probablemente ya está explicado o mediado por otras variables que sí están en el modelo. Por ejemplo, el efecto de una mala función renal (urea, cistatina) podría estar ya recogido por la gravedad clínica del paciente (Clase Killip) y sus niveles de BNP, que son predictores más directos en el modelo ajustado. Este es un ejemplo perfecto de confusión estadística y la razón por la que el análisis multivariable es indispensable.

3.3. Validación

Discriminación: AUC La curva del modelo, mostrada en la Figura 4.1, se sitúa muy por encima de la línea diagonal de no discriminación (línea de azar), lo que indica visualmente una alta capacidad para distinguir entre los pacientes que fallecieron y los que sobrevivieron a los 6 meses.

El Área Bajo la Curva (AUC) fue de 0.910 (IC 95 %: 0.866-0.954), lo cual corresponde a una capacidad de discriminación excelente según las guías de interpretación convencionales. Este resultado confirma que el modelo es muy eficaz a la hora de asignar una mayor probabilidad de riesgo a los pacientes que efectivamente experimentaron el evento de muerte.

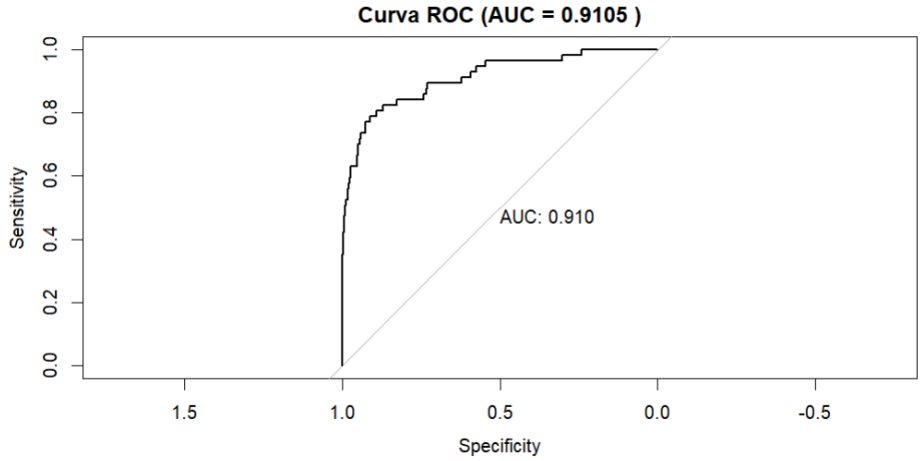

Figura 4.1: Curva ROC del modelo pronóstico final.

.

Calibración: Hosmer-Lemeshow El resultado de la prueba fue estadísticamente significativo ($\chi^2(8) = 15.627$, $p = 0.048$). Dado que el p-valor es inferior al umbral convencional de 0.05, se rechaza la hipótesis nula de que el modelo está bien calibrado. Esto sugiere la existencia de una discrepancia estadísticamente significativa entre las probabilidades de muerte predichas por el modelo y las frecuencias de muerte realmente observadas en los diferentes grupos de riesgo.

Calibración: Gráfico La calibración del modelo final se evaluó mediante un gráfico de calibración 4.2. Los resultados demostraron una calibración excelente. Visualmente, la curva de calibración aparente se alinea casi perfectamente con la diagonal de calibración ideal. Este hallazgo fue confirmado por las métricas de la propia gráfica, que mostraron un intercepto de calibración de 0.0 y una pendiente de 1.0, valores considerados óptimos. Es destacable que, si bien la prueba de Hosmer-Lemeshow arrojó un resultado estadísticamente significativo, lo que sugiere una posible falta de calibración, la evaluación visual y paramétrica del gráfico de calibración indicó un rendimiento excelente. Dadas las conocidas limitaciones del test de Hosmer-Lemeshow, como su sensibilidad al número de grupos y su menor potencia en ciertas condiciones, y la fuerte evidencia visual de una buena calibración, se considera que el rendimiento de calibración del modelo es aceptable para su propósito, aunque no perfecto según el test estadístico formal.

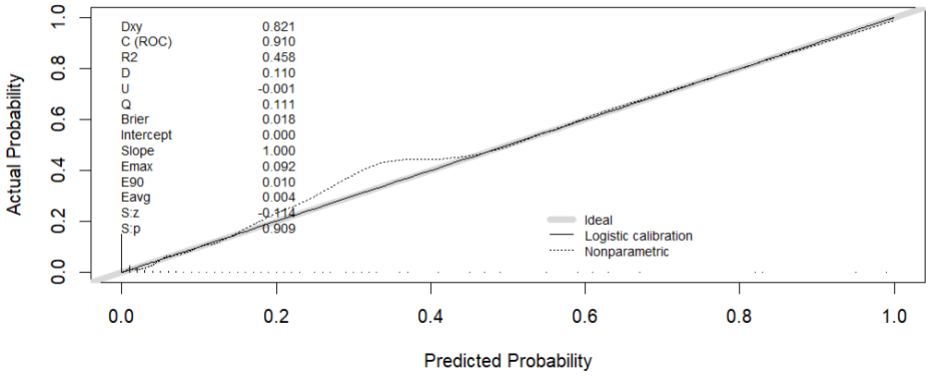

Figura 4.2: Gráfico de calibración

Validación Cruzada de 10 Folds El modelo alcanzó una Accuracy promedio del 97.6 %. No obstante, debido al desbalance de clases inherente al problema, se consideró el índice Kappa de Cohen como una medida de rendimiento más fiable. El Kappa obtenido fue de 0.332, lo que indica un nivel de acuerdo aceptable. Este resultado sugiere que, si bien la fortaleza principal del modelo reside en su excelente capacidad de discriminación (AUC) y calibración, su habilidad para la clasificación individual es modesta pero estadísticamente significativa.

3.4. Modelo Pronóstico

La Tabla 4.2 presenta el sistema de puntuación detallado. Para ilustrar su aplicación, se puede tomar el caso de un paciente hipotético que ingresa con una gravedad clínica moderada (Killip Grado II), pero que cuenta con un diagnóstico previo de insuficiencia cardíaca congestiva y presenta un nivel de Urea en el rango de (8.03, 11.5]. Al consultar la tabla, el clínico sumaría los puntos partiendo de los -528 puntos base, añadiendo 73 puntos por el grado Killip, restando 176 puntos por el factor protector del diagnóstico previo y restando 1 punto adicional por el nivel de urea. El cálculo total arroja una puntuación final de -632 puntos.
Una vez obtenida esta puntuación, se utiliza la Tabla 4.3 para estratificar al paciente. Una puntuación de -632 sitúa al individuo en la categoría de Riesgo Bajo, al ser inferior

al umbral de -116. Clínicamente, esto se traduce en una probabilidad de mortalidad a 6 meses inferior al 20 %, lo que podría guiar al equipo médico hacia un manejo clínico estándar, sin necesidad de intervenciones de alta complejidad.
De esta manera, el score pronóstico funciona como un puente eficaz entre el modelo estadístico y la decisión clínica, traduciendo múltiples variables en un único indicador de riesgo estratificado y fácilmente interpretable.

Cuadro 4.2: Tabla de Puntuación Detallada del Modelo Pronóstico

Variable Predictora	**Categoría o Valor**	**Coef. β**	**Puntos Asignados**
PUNTOS BASE (Intercepto)	-	-6.31	-528
Killip Grade	Grado II	0.87	73
	Grado III	1.87	157
	Grado IV	2.86	240
	Grado I (Ref.)	0	0
Congestive Heart Failure	Presente	-2.10	-176
	Ausente (Ref.)	0	0
Liver Disease	Presente	1.50	125
	Ausente (Ref.)	0	0
Respiratory Failure Type II	Presente	1.11	93
	Ausente (Ref.)	0	0
Acute Renal Failure	Presente	1.87	157
	Ausente (Ref.)	0	0
Consciousness	Nonresponsive	56.07	4693
	Responsive To Pain	18.00	1507
	Responsive To Sound	0.06	5
	Alert (Ref.)	0	0
FiO2	(33, 100]	0.37	31
	$\leq 33(Ref.)$	0	0

Cuadro 4.2: Tabla de Puntuación Detallada del Modelo Pronóstico (Continued)

Variable Predictora	**Categoría o Valor**	**Coef. β**	**Puntos Asignados**
Creatinine (Enzymatic)	(65.1, 87.1]	-0.01	-1
	(87.1, 122]	-0.35	-29
	(122, 963]	0.32	27
	$\leq 65.1(Ref.)$	0	0
Urea	(5.91, 8.03]	0.60	51
	(8.03, 11.5]	-0.01	-1
	(11.5, 45.6]	0.35	30
	$\leq 5.91(Ref.)$	0	0
Cystatin	(1.22, 1.55]	-0.27	-23
	(1.55, 2.17]	0.21	18
	(2.17, 10.4]	0.01	1
	$\leq 1.22(Ref.)$	0	0
Platelet	(101, 135]	0.32	27
	(135, 176]	-0.59	-49
	(176, 646]	0.44	37
	$\leq 101(Ref.)$	0	0
Neutrophil Ratio	(0.684, 0.759]	0.41	98
	(0.759, 0.826]	1.17	35
	(0.826, 0.976]	1.33	111
	$\leq 0.684(Ref.)$	0	0
Thrombin Time	(16.3, 17.2]	1.41	118
	(17.2, 17.9]	0.64	54
	(17.9, 209]	1.39	116
	$\leq 16.3(Ref.)$	0	0
Glutamic Oxaloacetic Transaminase	(21, 26]	-0.82	-68
	(26, 36]	0.42	35
	(36, 6.64e+03]	-0.33	-28
	$\leq 21(Ref.)$	0	0

Cuadro 4.2: Tabla de Puntuación Detallada del Modelo Pronóstico (Continued)

Variable Predictora	**Categoría o Valor**	**Coef. β**	**Puntos Asignados**
Creatine Kinase	(67, 91]	1.05	87
	(91, 126]	1.40	117
	(126, 5.92e+03]	0.94	79
	$\leq 67(Ref.)$	0	0
Creatine Kinase Isoenzyme	(12.5, 16.1]	-0.93	-78
	(16.1, 20.7]	-1.03	-86
	(20.7, 424]	-0.85	-71
	$\leq 12.5(Ref.)$	0	0
Brain Natriuretic Peptide	(312, 753]	-0.19	-16
	(753, 1.72e+03]	1.06	88
	(1.72e+03, 5e+03]	1.00	84
	$\leq 312(Ref.)$	0	0
White Globulin Ratio	(1.2, 1.3]	0.14	12
	(1.3, 1.5]	0.35	29
	(1.5, 2.6]	-0.82	-68
	$\leq 1.2(Ref.)$	0	0
Globulin	(24.9, 27.9]	-0.24	-20
	(27.9, 31.2]	-0.31	-26
	(31.2, 88.3]	-0.12	-10
	$\leq 24.9(Ref.)$	0	0
GCS	Moderado (9-12)	0.88	73
	Grave (3-8)	-34.68	-2903
	Leve (13-15) (Ref.)	0	0

Cuadro 4.3: Niveles de riesgos estimados según puntuación

Grupo de Riesgo	**Riesgo de Mortalidad**	**Puntuación Requerida**
Bajo	$< 20\,\%$	< -116
Medio	$20\,\%$ - $70\,\%$	-116 a 71
Alto	$> 70\,\%$	> 71

Capítulo 5

Conclusiones

- El método de regularización LASSO es una herramienta de selección de variables superior a los enfoques clásicos stepwise en contextos de alta dimensionalidad, ya que permite obtener modelos más parsimoniosos y robustos frente al sobreajuste, como se ha demostrado en la aplicación práctica.
- Los índices pronóstico (scores) constituyen un puente esencial entre la modelización estadística compleja y la práctica clínica. Su valor reside en su capacidad para traducir la evidencia de los datos en una herramienta simple e interpretable que apoya la toma de decisiones médicas.
- La validación interna es una etapa indispensable para evaluar la robustez de un modelo, mientras que la validación externa es la prueba definitiva y fundamental para confirmar su generalizabilidad y valor clínico en poblaciones diversas, siendo un requisito para su implementación segura.
- El índice pronóstico desarrollado a partir de los predictores seleccionados demuestra una excelente capacidad de discriminación (AUC = 0.910), confirmando que es una herramienta muy eficaz para diferenciar entre pacientes de alto y bajo riesgo de mortalidad a 6 meses.
- La categorización de las variables continuas es una de las decisiones más críticas en la construcción de un score. La elección entre umbrales clínicos y cuantiles basados en datos impacta directamente en el equilibrio entre la interpretabilidad del modelo y su rendimiento predictivo.
- La estratificación del riesgo en tres niveles en los datos analizados proporciona una herramienta final fácil de interpretar para la toma de decisiones.
- La línea de investigación prioritaria para el futuro sería la validación externa del score en cohortes de pacientes diversas para evaluar su generalizabilidad. Adicionalmente, sería de gran interés realizar un análisis de impacto clínico para determinar si el uso de la herramienta mejora los resultados de los pacientes y comparar su rendimiento con el de modelos de machine learning más complejos.

Bibliografía

Benavent, D., Colomer, J., Quecedo, L., Gol-Montserrat, J., and del Llano Señarís, J. E. (2020). *Inteligencia artificial y decisiones clínicas: cómo está cambiando el comportamiento del médico.* Fundación Gaspar Casal.

Collett, D. (2015). *Modelling survival data in medical research.* CRC press, third edition.

Collins, G. S., Reitsma, J. B., Altman, D. G., and Moons, K. G. (2015). *Transparent Reporting of a multivariable prediction model for Individual Prognosis Or Diagnosis (TRIPOD): the TRIPOD statement.* Annals of internal medicine.

Gu, W., Wang, F., Liu, T., and Qin, Y. (2022). *A new predictor of all-cause mortality in patients with heart failure: The waist-to-height ratio.* BMC Medical Informatics and Decision Making,.

Han, J., Kamber, M., and Pei, J. (2012). *Data Mining: Concepts and Techniques.* Morgan Kaufmann, third edition.

Hanke, M., Dijkstra, L., Foraita, R., and Didelez, V. (2024). Variable selection in linear regression models: choosing the best subset is not always the best choice. *Biometrical Journal*, 66(1):2200209.

Harrell, F. E. (2015). *Regression modeling strategies: with applications to linear models, logistic regression, and survival analysis (2nd ed.).* Springer.

Hemingway, H., Croft, P., Perel, P., Hayden, J. A., Abrams, K., Timmis, A., and the PROGRESS Partnership (2013). Prognosis research strategy (progress) 1: a framework for research into disease prognosis. *BMJ*, 346:e5595.

Hoerl, A. E. and Kennard, R. W. (1970). *Ridge regression: Biased estimation for nonorthogonal problems.* Technometrics.

Hosmer, D. W. and Lemeshow, S. (1980). *A goodness-of-fit test for the multiple logistic regression model.* Communications in Statistics-Theory and Methods,.

Hosmer, D. W., Lemeshow, S., and Sturdivant, R. X. (2013). *Applied Logistic Regression.* Wiley, third edition.

Huang, Y., Li, W., Macheret, F., Gabriel, R. A., and Ohno-Machado, L. (2020). A tutorial on calibration measurements and calibration models for clinical prediction models. *Journal of the American Medical Informatics Association*, 27(4):621–633.

Iwagami, M. and Matsui, H. (2022). Introduction to clinical prediction models. *Annals of Clinical Epidemiology*, 4(3):72–80.

Moons, K. G., Kengne, A. P., Grobbee, D. E., Royston, P., Vergouwe, Y., Altman, D. G., and Woodward, M. (2012). Risk prediction models: Ii. external validation, model updating, and impact assessment. *Heart*, 98(9):691–698.

Nguyen, L. and Graviss, E. A. (2018). A simple prognostic score for tuberculosis mortality in texas. *Journal of Clinical Epidemiology*, 95:56–65.

Steyerberg, E. W. (2019). *Clinical Prediction Models: A Practical Approach to Development*. Springer Nature.

Steyerberg, E. W., Moons, K. G. M., van der Windt, D. A., Hayden, J. A., Perel, P., Schroter, S., and the PROGRESS Group (2013). Prognosis research strategy (progress) 3: prognostic model research. *PLoS Medicine*, 10(2):e1001381.

Tibshirani, R. (1996). *Regression shrinkage and selection via the lasso.* Journal of the Royal Statistical Society: Series B (Methodological),.

Vickers, A. J. and Elkin, E. B. (2006). *Decision curve analysis: a novel method for evaluating prediction models.* Medical decision making.

Visseren, F. L. J., Mach, F., Smulders, Y. M., Carballo, D., Koskinas, K. C., Bäck, M., , and others for the ESC National Cardiac Societies (2021). 2021 esc guidelines on cardiovascular disease prevention in clinical practice. *European Heart Journal*, 42(34):3227–3337.